

分类号：TP249

学校代码：82701

密级：公开

机械科学研究总院 硕士学位论文

基于多源传感信息融合的移动 机器人定位算法研究

Research on Mobile Robot Localization Algorithm Based on Multi-source Sensor Information Fusion

培养单位：机械科学研究总院

专 业：机械制造及其自动化

研 究 方 向：移动机器人

研究生姓名：赵宇轩

指 导 教 师：公建宁 正高级工程师

副指导教师：陈 浩 正高级工程师

2023年6月14日

摘 要

随着移动机器人行业的快速发展,日趋复杂的应用场景对移动机器人的性能有了更高的要求。在移动机器人的关键技术中,稳定、高效及准确的定位算法是实现自主导航功能的核心。在传统定位技术中,采用单一传感器的定位算法有各自局限性,在实际运行场景下,情况复杂多样,行程位置易发生丢失。

为结合多种传感器的优点,提高移动机器人的感知定位能力,本文对基于多源传感信息融合的定位算法进行了相关研究,以视觉方法与激光方法为基础,融合轮式编码器、RGB-D 相机、激光雷达、IMU 等多种传感器信息,从位姿跟踪与全局定位两方面改进了移动机器人定位算法。研究主要包含以下三个部分:

(1) 在移动机器人前端定位过程中,针对单一传感器存在的定位精度低、发生退化等问题,利用视觉相机、IMU 与轮式编码器等多种传感器,进行了基于多源传感信息融合的前端定位算法研究。算法构建了基于编码器初始位姿的视觉里程计跟踪模型;建立了各传感器的运动观测,并取滑动窗口对其残差项进行最小二乘优化,实现了多传感器运动信息的非线性优化融合,最终完成对移动机器人位置、姿态等运动状态信息的精准跟踪。

(2) 针对移动机器人的定位丢失与未知位置启动等问题,基于视觉与激光结合的方法进行了全局定位算法研究。在建图过程中,利用视觉 SLAM 与激光 SLAM,分别建立特征点地图与激光栅格地图,记录关键帧序列与机器人位姿,并生成地图间的位姿映射关系;在进行全局定位时,利用词袋模型进行视觉快速定位,并通过地图对齐得到栅格地图中的先验定位信息,基于自适应蒙特卡罗定位算法更新粒子直至收敛,实现准确、高效率的全局定位。

(3) 为验证算法有效性,搭建实验平台进行了一系列实车测试。在室内大厅环境下,将本文的前端定位算法和全局定位算法,分别与基于单一传感器的里程计与 AMCL 算法进行了对比实验。实验结果表明,本文算法在前端运动轨迹的精度方面有明显提升,同时大幅提高了全局定位的效率与成功率,保证了移动机器人在复杂环境下的稳定运行。

关键词: 移动机器人;多传感器融合;前端定位;全局定位

ABSTRACT

With the rapid advancement of the mobile robotics industry, increasingly complex application scenarios have placed higher demands on the performance of mobile robots. In the field of modern mobile robots, a stable, efficient and accurate localization algorithm is the core component for realizing autonomous navigation capabilities. Traditional localization techniques based on single sensor algorithms have inherent limitations. In complex and diverse situations, the risk of losing location is evident.

To combine the advantages of multiple sensors and enhance the perception and localization capabilities of mobile robots, this paper delves into relevant research on localization algorithms based on the fusion of multiple sensor sources information. This approach integrates visual and laser methods and combines sensors information from wheel encoders, RGB-D cameras, LiDAR, IMU, thereby improving the localization algorithms for mobile robots in terms of pose tracking and global localization. The research primarily consists of the following three parts:

(1) In the front-end localization process of mobile robots, to address the issues of low positioning accuracy and degradation associated with single-sensor approaches, a front-end localization algorithm based on fusion of multi-source sensor information is developed. The algorithm constructs a visual odometry tracking model based on the initial pose from the wheel encoders. It establishes motion observations from various sensors, and employs a sliding window to perform least squares optimization on residual terms, thus achieving nonlinear fusion of motion information from multiple sensors. Ultimately, this enables accurate tracking of the mobile robot's position, orientation, and other motion state information.

(2) To address challenges such as localization loss or initialization with unknown position, a global localization algorithm based on the fusion of visual and laser techniques is investigated. In the mapping process, feature-based mapping of visual SLAM and grid-based mapping of laser SLAM are built. Keyframe sequences and robot poses are recorded, and pose mapping relationships between maps are established. During global localization, rapid visual localization is achieved using a bag-of-words model, and prior localization information from the grid map is obtained through map alignment. The adaptive Monte Carlo localization algorithm updates particles until convergence, enabling accurate and efficient global localization.

(3) To validate the effectiveness of the algorithms, an experimental platform was set up for a series of real vehicle tests. In an indoor hall environment, a comparative analysis was conducted between the front-end localization algorithm and the global localization algorithm proposed in this research against odometer and the AMCL algorithm based on a single sensor. The experimental results demonstrate a significant improvement in the accuracy of front-end motion trajectory, while greatly enhancing the efficiency and success rate of global localization. This ensures stable operation of the mobile robot in complex environments.

Zhao Yuxuan (Mechanical manufacturing and Automation)

Directed by prof. Gong Jianning, prof. Chen Hao

KEY WORDS: mobile robot; multi-sensor fusion; front-end localization; global localization

目 录

第 1 章 引言.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 激光定位研究现状.....	2
1.2.2 视觉定位研究现状.....	6
1.2.3 IMU 与轮式编码器研究现状.....	10
1.3 主要研究内容.....	12
第 2 章 基于多源传感信息融合的前端定位算法研究	14
2.1 前端定位算法框架.....	14
2.2 轮式编码器运动观测.....	15
2.3 视觉里程计运动观测.....	16
2.4 IMU 运动观测.....	22
2.5 多传感器信息融合.....	23
2.5.1 最小二乘问题构建.....	23
2.5.2 残差计算与优化求解.....	25
2.6 小结.....	28
第 3 章 视觉与激光结合的全局定位算法研究	30
3.1 算法理论基础.....	30
3.2 全局定位算法框架.....	31
3.3 基于词袋模型的视觉快速定位	33
3.4 建立地图间位姿映射.....	35
3.5 基于 AMCL 方法的精确定位.....	37
3.6 小结.....	39
第 4 章 实验验证与分析	40
4.1 实验平台.....	40
4.2 传感器标定.....	43
4.3 前端定位实验.....	44
4.3.1 评价指标.....	44
4.3.2 实验过程与结论.....	45
4.4 全局定位实验.....	47
4.5 小结.....	52
第 5 章 总结与展望	53
5.1 本文的主要工作.....	53
5.2 未来工作展望.....	54

参考文献.....	55
-----------	----

插图清单

图 1-1 Gmapping 算法建图效果	3
图 1-2 基于图优化的 SLAM 系统	4
图 1-3 Cartographer 算法建图效果	4
图 1-4 Cartographer 算法流程	5
图 1-5 ORB-SLAM3 算法基本框架	8
图 1-6 论文章节安排	12
图 1-7 研究技术路线	12
图 2-1 多源传感信息融合的前端算法框架	14
图 2-2 单舵轮移动机器人运动学模型	15
图 2-3 针孔模型的成像原理	17
图 2-4 相机畸变模型	18
图 2-5 特征匹配过程	19
图 2-6 视觉里程计特征匹配搜索过程	20
图 2-7 移动机器人运动观测滑动窗口示意图	24
图 2-8 重投影误差示意图	25
图 2-9 前端定位算法的图优化问题	28
图 3-1 蒙特卡洛定位算法流程	30
图 3-2 全局定位算法框架	32
图 3-3 基于词袋模型的共视关键帧搜索过程	33
图 4-1 移动机器人实验平台	40
图 4-2 R2000 单线激光雷达	40
图 4-3 Intel RealSense D455 深度相机	41
图 4-4 Kubler 增量式速度编码器	41
图 4-5 Advantech MIC-770 工控机	42
图 4-6 ROS 系统通讯机制	42
图 4-7 Apriltag 标定板	43
图 4-8 Camera-LiDAR 联合标定	44

图 4-9 绝对轨迹误差	44
图 4-10 相对轨迹误差	45
图 4-11 各位姿估计方法下的实验平台运动轨迹	46
图 4-12 运动轨迹误差折线图	47
图 4-13 栅格地图与特征点地图	48
图 4-14 AMCL 算法定位失败	50
图 4-15 粒子收敛过程	51

表格清单

表 1-1 传统方法的视觉定位经典算法	9
表 1-2 直接法与特征点法优缺点对比	10
表 4-1 前端定位实验结果（单位：m）	46
表 4-2 全局定位实验结果	48
表 4-3 全局定位算法实验对比结果汇总	51

第1章 引言

1.1 研究背景与意义

随着计算机技术与人工智能理论的普及，移动机器人技术的迅速发展和广泛应用已经在多个领域发挥了重要作用，包括制造业、医疗、服务和物流等。根据市场研究数据，全球移动机器人市场规模不断扩大，并预计未来仍有增长潜力。在中国，政策和市场的双重导向促进了移动机器人产业的快速发展，这为移动机器人技术的研究和应用提供了良好的机遇。国际机器人联合会发布的《2022 年全球机器人报告》显示，2021 年全球工厂新安装了 51 万 7385 台工业机器人，同比增长 31%，比疫情前的 2018 年高出 22%，创下历史新高。同时，全球运行中的机器人存量约为 350 万台，亦创下了新的纪录。

移动机器人技术的研究起源于 20 世纪 70 年代，这一技术在过去几十年中得到了持续的发展和完善。近年来，移动机器人相关产业快速发展，得益于政策和市场的促进，提升机器人技术水平已经成为了国家制造业发展战略的一部分。2021 年末，我国工业和信息化部等部门发布了《“十四五”机器人产业发展规划》，提出重点推进工业机器人、服务机器人和特种机器人重点产品的研制及应用，提升性能、质量和安全性，推动产品高端化智能化发展。规划提出，到 2025 年，我国成为全球机器人技术创新策源地、高端制造集聚地和集成应用新高地，制造业机器人密度实现翻番；到 2035 年，我国机器人产业综合实力达到国际领先水平，机器人成为经济发展、人民生活、社会治理的重要组成。移动机器人正在为世界各国解决劳动力成本提高、产业转型升级等社会问题提供途径，在不断创新和发展的推动下，移动机器人技术将会在更广泛的领域得到应用和发展。

移动机器人可分为 AMR(Autonomous Mobile Robot)与 AGV(Automated Guided Vehicle)，其中，AMR 在工作环境中无需人工预设标记物，能够实现环境实时感知与传感器观测信息处理，相比传统的固定式机器人，可以根据任务需求自由移动，无需受到固定轨道的限制，且能够感知环境变化并实时做出决策，适应不同的工作环境和任务需求。AMR 具备灵活性与适应性，可以在非结构化的工作环境中自主完成导航。

定位算法是移动机器人系统实现自主作业能力的核心组成部分之一，其作用是根据传感器观测信息确定机器人在环境中的位置和姿态信息，以实现机器人探测、定位和跟踪地面上某个物体、地点或者路径的任务。可靠的定位算法是机器人自主

运动的基础，也是机器人自主导航的前提，它关系到机器人在执行各种任务时能否正确地理解环境、规划路径和避免障碍。

移动机器人定位算法包含全局定位与位姿跟踪两部分：全局定位即为绝对定位，指机器人在初始位置未知的情况下，靠自身运动确定其在地图中的位姿；位姿跟踪即为相对定位，指在有较为准确初始位姿的前提下，通过里程计信息确定机器人运动姿态，保持对机器人位置的跟踪。

传感器在定位技术中扮演着非常重要的角色。然而，采用单个传感器的定位算法通常具有一定的局限性，如在信号较弱、具有强干扰或信号缺失的室内环境下难以采用基于射线/电信号计算的定位方法；而惯性导航定位法只能计算机器人的位置，无法感知环境中的其他物体，需要结合其他定位方法来实现机器人在环境中的导航和避障，同时由于加速度计和陀螺仪等的漂移问题，定位误差会逐渐增大，需要进行定期校准等。

因此，采用多传感器融合的方法，利用不同传感器的互补性，可以有效地弥补单个传感器存在的问题，以提升定位算法的精度和可靠性。例如，激光定位算法在光线不足或纹理缺失的环境下表现良好，而视觉定位则可在结构相似环境中提供更多的信息；惯性测量单元（Inertial Measurement Unit, IMU）和轮式编码器等运动测量传感器能够高频地获取机器人内部的运动信息，并且不受周围环境的影响，从而弥补相机在快速运动、光照改变等情况下容易失效的问题；同时，相机能够获得丰富的环境信息，并且通过视觉匹配完成回环检测与回环校正，从而有效地修正 IMU 和轮式编码器的累计漂移误差。

综上所述，本论文针对自主移动机器人定位功能，融合不同传感器的数据实现移动机器人前端位姿跟踪与全局定位算法，以提高定位过程的鲁棒性和高效性，进而提升综合定位能力，对于解决移动机器人复杂环境定位问题具有重要研究意义。

1.2 国内外研究现状

1.2.1 激光定位研究现状

激光雷达定位算法通过机器人搭载的激光雷达设备扫描环境，测量环境中障碍物的位置和形状等信息，从而实现机器人在环境中的位置推算。激光雷达包含激光发生器、光路系统以及扫描探测机构，其工作时发出并接收激光束，采用飞行时间测距（Time of Flight, TOF），即通过探测器向目标物发送一束短脉冲的激光或红外光信号，记录信号发出和回收的时间差，并用其计算出信号所经过的距离，为定位算法提供观测信息。激光雷达定位算法可以实现高精度的定位和避障，因此在自动驾驶、无人机等领域中有广泛应用。

激光雷达定位算法的早期研究使用扩展卡尔曼滤波（Extended Kalman Filter, EKF）估计机器人位姿。EKF 是一种常用的非线性状态估计方法，它通过在状态转移和测量方程中引入一阶泰勒近似，使其能够处理非线性模型。在激光雷达定位中，EKF 可用于将激光雷达测量数据与移动机器人动态模型进行融合，通过对机器人状态的预测和观测值的更新，递归地计算出最优估计，并且能够对估计结果进行不确定性评估，从而实现对机器人位置和姿态的估计。EKF 定位方面目前出现了较多研究进展，体现为利用 EKF 算法来构建环境特征地图，解决了部分场景下的机器人同步定位与地图构建（simultaneous localization and mapping, SLAM）问题^[1]。但实际的激光雷达定位问题是一个强非线性系统，使用 EKF 等滤波方法定位存在较大误差，并且存在协方差矩阵二次计算问题的复杂性等限制，使得 EKF 方法在大规模场景下的定位问题中的表现难以令人满意^[2]。

基于粒子滤波（Particle Filter, PF）方法的激光定位算法有效克服了非线性系统带来的问题。2000 年，Doucet 等研究者^[3]提出基于动态贝叶斯网络的 Rao-Blackwellized 粒子滤波算法；Montemerlo 等研究者^[4-5]在此基础上建立了 FastSLAM1.0 和 FastSLAM2.0 算法，它们使用贝叶斯滤波器来估计机器人位姿和地图特征，利用 PF 建立特征地图。此外，2007 年 Grisetti 等人^[6]提出了 Gmapping 算法，在前文 RBPF 的基础上改进了提议分布，并选择性地对粒子进行重采样，从而一定程度上避免了粒子退化，提高了定位精度，并通过减少粒子个数减少了计算量，使得该方法成为粒子滤波方法的经典算法，其建图效果如图 1-1 所示。



图 1-1 Gmapping 算法建图效果

粒子滤波方法存在粒子增多导致计算量增加的问题，并且基于滤波的方法随时间的累积误差也将逐渐增大，为了解决这些问题，研究者们相继提出了 Karto-Slam、Hector-Slam、Cartographer 等基于图优化且更加健壮的激光 SLAM 算法。图优化方法以图的形式表示机器人位姿的优化问题，其中节点代表待优化变量，边代表由观测产生的约束，其求解过程通常使用 L-M 法或高斯牛顿法，能够直观高效地求解优

化问题。通过对图进行优化，可以得到机器人运动轨迹的最优估计和地图的最优表示。相比于传统的粒子滤波方法，图优化方法能够考虑当前时刻和过去所有时刻状态，从而达到更好的定位和地图构建效果。随着 CPU 与存储设备的等硬件发展，采用非线性优化框架的定位算法中存在大量观测信息的问题得以改善^[7]，使得在激光雷达定位中，基于非线性优化求解的定位算法已经成为主流。




图 1-2 基于图优化的 SLAM 系统

2010 年，Kurt Konolige 等人^[8]提出了 Karto-SLAM 算法，该方法采用典型的基于图优化的 SLAM 系统，前端和后端以交错的方式执行，如图 1-2 所示；同时该方法使用稀疏姿态平差（Sparse Pose Adjustment, SPA）方法构造和求解线性子问题^[9]。Kohlbrecher 等^[10]提出的 Hector SLAM 则使用快速扫描匹配算法和多层次地图表示技术，无需里程计信息即可在实时性要求较高的情况下快速地完成地图构建，但该算法对地图初始化和激光雷达数据质量要求较高。



图 1-3 Cartographer 算法建图效果

在 2016 年，Google 提出 Cartographer 算法^[11]，该算法的建图效果如图 1-3 所示，其整体框架流程如图 1-4 所示，包括激光雷达位姿估计、环路闭合检测、位姿图优化和地图构建等部分。算法在前端部分将激光插入具有优化匹配的局部图形中，后端部分则采用以局部子图为单元的闭环检测，以消除建图过程中各子图产生的累

自适应蒙特卡洛定位 (Adaptive Monte Carlo Localization, AMCL) 算法对 MCL 算法进行改进, 它利用自适应采样机制和重要性权重更新策略, 提高了算法的效率和鲁棒性。AMCL 算法广泛应用于机器人定位, 特别是在复杂多变的环境下有着良好的表现, 如室内外、人流密集的公共场所等。

然而, 由于激光雷达特征单一, 激光雷达定位算法也存在一些问题, 无法适应所有场景。如激光雷达定位法对环境特征等因素较为敏感, 可能出现定位失效的情况; 以及高精度的多线激光雷达设备价格较高, 增加了移动机器人的成本等。针对激光雷达定位法的这些问题, 需要对现有算法进行不断的完善, 例如, 使用多个激光雷达设备进行定位, 提高环境感知能力; 结合其他传感器信息进行数据融合, 提高定位精度和鲁棒性; 使用 SLAM 算法来同时构建地图和估计机器人的位置等, 以提高算法的适用范围和定位精度。

1.2.2 视觉定位研究现状

视觉定位算法是一种低成本、高精度的定位方法, 广泛应用于无人机、自动驾驶汽车和移动机器人等领域。完整的视觉定位过程应包含前端与后端两部分, 前端处理完成图像帧间位姿估计的功能, 后端实现回环检测功能, 并对相机位姿与地图路标点进行优化处理, 以缩小整体误差。

视觉里程计 (Visual Odometry, VO)^[16]根据两帧间图像的变化求解帧间相机运动的变换关系, 因而视觉里程计通常作为 SLAM 的前端来使用, 在非结构化环境下实现自身定位^[17]。在上世纪八十年代, Matthies 等人^[18]探讨了如何从图像对应关系计算误差模型、估计帧间机器人运动以及随时间更新机器人和路标点的全局位置, 最早提出了特征提取、特征匹配、运动估计等模块的理论框架。2004 年, David 等人^[19]提出视觉里程计的概念。

传统的视觉定位方法可以按照传感器类型分为单目、双目和深度相机三类。其中, 单目视觉定位系统结构简单、成本低, 常用算法有 PTAM^[20]、SVO^[21]、DSO^[22]等。由于单目相机缺少深度信息, 需要平移相机才能估计深度信息, 但由于没有绝对的尺度信息, 单目视觉定位算法无法获得真实的距离, 因此容易在重复性低或者纹理信息不足的区域产生漂移等问题。

双目相机和深度相机能够获取图像中像素点对应障碍物的距离信息, 以解决单目视觉定位算法缺少尺度信息的不足。双目相机由两个固定间隔的相机组成, 通过计算两个相机间的视差来确定距离信息, 能够消除尺度的不确定性, 从而获取场景的三维结构, 但是视差的计算需要消耗大量计算资源。经典的双目视觉定位算法有 ORB-SLAM^[23-24]、RTAB-MAP^[25]等。深度相机使用红外结构光或者飞行时间差原理测距, 能够更直接地获取深度信息。经典的基于深度相机的视觉定位算法有 DVO^[26]、

RGB-D-SLAM-V2^[27]等，相比双目定位算法能够占用较少的计算资源，但受测量原理限制，其深度信息易受光线与障碍物材质等环境因素的影响，因此主要用于室内测量。在实际应用中，需要根据场景和要求选择适合的相机类型和测距方法。

根据处理图像的方式，视觉定位算法也可分为特征点法和直接法。特征点法通过提取图像中的特征点进行匹配，而直接法则利用像素亮度信息直接进行匹配。在完成图像帧间匹配后，可以利用对极几何约束计算出各视觉图像帧的位姿状态信息，从而实现定位和导航功能。

特征点法是视觉定位算法中较为常用的一种方法，它选取图像中具有代表性的特征点，通过比对这些点在相机视角少量改变后的像素位置来估计相机的运动轨迹。在早期的研究中采用灰度值的形式提取特征，然而受光照、材质等环境因素影响，某些图像区域的灰度值可能会发生变化，影响特征点的匹配，因此研究者们设计了更加稳定高效的 SIFT^[28]、SURF^[29]、ORB（Oriented FAST and Rotated BRIEF）^[30]等特征点与描述子，以提高特征匹配的准确性和鲁棒性，并采用局部和全局优化等算法对运动轨迹进行优化，如 MonoSLAM^[31]、PTAM、ORB-SLAM、VINS-Mono^[32]等是基于特征点法的常用算法。

其中，ORB-SLAM3^[33]是一种基于图像特征和非线性优化的视觉定位算法，是第一个能够使用针孔和鱼眼镜头模型、单目、双目和 RGB-D 相机执行视觉、视觉惯性和多地图 SLAM 的系统，其算法框架如图 1-5 所示。系统采用 ORB 特征进行追踪、建图和位置识别任务，这种特征具有旋转不变性和尺度不变性，能够迅速提取和匹配特征，并在基于词袋的位置识别过程中表现优异。在跟踪线程中，系统所有的运行都基于输入图像的特征展开，不依赖于相机类型，并将特征点分为远处特征点和近处特征点两类进行处理。在建图线程中，算法使用多地图系统，基于改进的路标点识别方法提高了召回率，让定位系统在长时间缺乏视觉信息的情况下仍然能够保持工作，更加准确地描述场景信息。系统在回环检测阶段通过执行位姿图优化来更正漂移误差，在全局 BA 优化阶段对关键帧和特征点子集进行更新，并插入前期未参与优化的关键帧和特征点进行融合，使得系统在所有算法阶段都能够重复使用先前高视差的共视关键帧中包含的图像信息。ORB-SLAM3 开源代码具有较高的清晰度和可读性，在定位精确度还有鲁棒性等方面都十分优秀，是视觉定位领域最具代表性的基于特征点法的开源项目^[34]。




图 1-5 ORB-SLAM3 算法基本框架

但是，特征点法也存在一些局限性，例如在图像信息存在特征缺失的情况下，会导致算法运动估计的不准确；同时特征点法只提取了图像中的少部分信息，使得估计相机运动的精度有限，构建的地图通常也是稀疏的；此外，特征点提取与描述子计算对计算性能的要求相对更大。

直接法的视觉定位算法与特征点法不同，它在计算过程中耗费的时间相对较少，无需获取点与点之间的对应关系，而是直接根据像素灰度的变化来估计相机位姿，因此直接法只提取特征点，而跳过描述子的计算与特征匹配，以更整体的方式处理了数据关联问题。直接法可用于构建稠密地图，因其在图像上每一像素都有可能成为关键点，从而保证了建图的稠密性。但如 LK 光流法等直接法均将灰度不变假设作为基本条件，即认为同一路标点在各关键帧的投影处的像素灰度保持不变。但灰度不变假设是一个强假设，在实际工况中可能发生失效，例如由于物体的材质不同，像素会出现高光和阴影部分；或因相机调整曝光参数，使得图像整体变亮或变暗，在此类情况下，直接法的定位效果会受到影响，导致算法鲁棒性较差。常用的基于直接法的视觉定位算法有 DTAM^[35]、DSO^[22]、DVO^[26]等。

表 1-1 列出了经典的基于传统方法的视觉定位算法。

表 1-1 传统方法的视觉定位经典算法

系统名称	相机类型	发布年份	处理方法	优化方法	特性
MonoSLAM	单目	2007	特征点法	EKF 滤波	首个实时的单目 VO
PTAM	单目	2007	特征点法	非线性优化	首个非线性优化的 VO
STAM	单目	2011	直接法	非线性优化	稠密光流的实时系统
SVO	单目	2014	直接法、特征点法	非线性优化	半直接法
OKVIS	单目、双目	2015	特征点法	EKF 滤波	视觉+惯性测量
DSO	单目	2016	直接法	非线性优化	稀疏直接法
VINS-Mono	单目	2017	特征点法	非线性优化	紧耦合方法
ORB-SLAM3	单目、双目、RGB-D	2020	特征点法	非线性优化	检测完整历史数据的 VO
RTAB-MAP	双目、RGB-D	2011	直接法	非线性优化	解决在线闭环检测问题
Kinect Fusion	RGB-D	2011	直接法	非线性优化	实时 3D 室内重建
DVO	RGB-D	2013	直接法	非线性优化	密集直接法
RGB-D-SLAM-V2	RGB-D	2014	直接法	非线性优化	纯视觉里程计

基于直接法与特征点法的视觉定位算法优缺点不同，适应于不同的定位要求，其对比如表 1-2 所示。基于特征点的视觉定位方法更加稳定，且在移动机器人定位

建图系统中更利于进行回环检测与全局定位，所以特征点法成为当前视觉定位方案的主流选择。

表 1-2 直接法与特征点法优缺点对比

方法	优点	缺点
直接法	速度快，无特征点的计算	灰度假设不易满足
	可构建稠密地图	不适合尺度较大的运动
	适用于特征缺失的场景	易受相机影响
特征点法	特征点稳定存在	特征点提取耗时
	适合尺度较大的运动	只能构建稀疏地图
	鲁棒性强	过度依赖特征点

此外，深度学习的发展为计算机视觉领域带来了巨大的推动力，在视觉定位算法方面，基于深度学习的方法具有准确率高、鲁棒性好、执行效率高等优点。相比传统视觉定位算法的严格几何理论方法，基于深度学习的算法通过寻找数据规律与目标任务之间的函数关系来完成任务，从而在不同的应用场景下展现出了出色的表现。例如 Sen Wang 等人^[36]提出了一种新型单目视觉里程计框架 DeepVO，使用 RCNNs 神经网络以端到端方式进行训练和部署，可以直接从一系列原始 RGB 图像中推断出相机姿态，而不采用传统视觉里程计流程中的任何模块。基于 RCNNs，其不仅可以通过卷积神经网络自动学习视觉定位问题的有效特征表示，还可以使用深度循环神经网络隐式地建模顺序动态和关系。此外，GeoNet^[37]、CNN-SLAM^[38]等基于深度学习的算法也已经成为视觉定位领域的代表性方案，受到广泛关注和应用。

1.2.3 IMU 与轮式编码器研究现状

IMU 和轮式编码器被广泛用作移动机器人的运动信息采集设备，能够通过实时采集物理信息来估计机器人的位置和姿态，且不受周边环境特征的影响。然而，受限于其工作原理，其传感器信息在部分运动场景下可能受到影响，如 IMU 在移动机器人低速、匀速运动时，运动观测可能发生退化等，从而导致位姿估计的性能不能满足实际需求；并且由于误差的累积，经常需要定期进行绝对位置修正。为了提高其性能，近年来国内外的学者在 IMU 和轮式编码器的参数标定等方面进行了广泛的研究，从而使其定位信息更加准确和可靠。

IMU 是测量物体三轴姿态角（或角速率）以及加速度的传感器，其通常包含三个单轴的加速度计和三个单轴的陀螺，根据惯性定律对加速度和角速度的测量值进行积分计算，推算出机器人在空间中的位置、速度和方向。IMU 早在上世纪 90 年代便开始规模应用于汽车与国防领域，相关的位姿估计技术已较为成熟。

基于 IMU 的定位方法对传感器信息的准确性很敏感,其精度和稳定性会受到多种因素的影响,如加速度计和陀螺仪的温度、机械振动等,随着行程的增加,会导致定位结果存在误差累积,需要进行 IMU 参数标定,以降低 IMU 参数误差的方式校准其测量精度,提高位姿估计性能。目前,常用的校准方法包括硬件校准、软件校准和组合校准等。

为了从原始位置、姿态数据和惯性测量单元获得高质量和高速率的估计,Scandaroli 等人在对 IMU 测量原理分析的基础上,提出了非线性观测器,通过在线识别各种测量偏差来改善估计,同时进行位置估计和加速度计偏差估计^[39]。程骏超等人^[40]提出一种不依赖转台精度的静态解析标定方法,采用多位置静态解析法粗标定出 IMU 系统参数,并根据惯性导航算法基本误差方程,建立以 IMU 系统参数粗标定结果的残差为估计对象,以 IMU 速度误差为观测量的 EKF 滤波器,估计出系统参数残差,进一步修正粗标定结果,降低了惯导系统的标定成本,满足高精度激光陀螺 IMU 的使用需求。赵桂玲等人^[41]提出通过坐标系转换矩阵建立 IMU 标定数学模型的方法,客观分析了 IMU 标定模型误差对捷联惯性导航系统导航参数的影响。

轮式编码器包括光电式、磁电式和触电电刷式等,如光电式编码器由光栅盘和光电检测装置组成,可以测量驱动轮的转动角度和速度,在移动机器人运动学模型下,根据各车轮速度信息与几何关系,完成机器人位置和姿态的计算。基于轮式编码器的定位算法是一种简单、廉价且易于实时完成的方法,但在移动机器人转向或行驶于颠簸路面时,其车轮与地面间常存在打滑现象;且轮式编码器位姿估计精度受移动机器人结构参数的测量误差影响,使得其定位结果误差较大。

为提升轮式编码器传感信息的可靠性,Abbas 等人^[42]提出了双向圆路径测试标定方法,方法可通过对轮式编码器标定参数进行系统校准,用于测量和校正差分驱动移动机器人中由运动学不完美性引起的系统测距误差;Tur 等人^[43]提出了一个闭合形式的表达式,基于运动学模型导出的协方差矩阵计算机器人里程计位置估计的不确定性。

研究者们为提高 IMU 和轮式编码器的位姿估计性能,主要关注传感器参数标定技术,通过传感器标定减少系统测量误差对位姿估计性能的影响。然而受原理与标定样本限制,实际定位结果仍难以避免随机测量误差的影响。因此,在移动机器人领域,学者们开始探索将 IMU、轮式编码器与其他传感器融合的多源传感信息融合方法,以将不同传感器的优势相互结合,从而降低单个传感器的限制对位姿估计的影响,并且能够在保证实时性的情况下,提高移动机器人定位与导航系统的综合效果。目前,常用的融合方法包括扩展卡尔曼滤波、无迹卡尔曼滤波、粒子滤波等基于滤波的方法和高斯牛顿法和 LM 算法等基于非线性优化的方法等。

1.3 主要研究内容

论文对基于多源传感信息融合的移动机器人定位算法进行了相关研究，基于非线性优化的方式实现了一种多传感器融合的位姿跟踪算法，基于视觉词袋模型实现了一种结合视觉与激光结合的全局定位算法，并搭建实验平台进行了一系列实车测试。

论文的章节安排如图 1-6 所示，全文共五个章节。




图 1-6 论文章节安排




图 1-7 研究技术路线

算法的技术路线如图 1-7 所示，主要研究内容如下：

第一章：引言。结合移动机器人技术的应用与发展，概述了本课题对移动机器人定位算法进行研究的背景与意义。对基于不同传感器的移动机器人定位算法的国内外研究现状加以简述，并分析了多源传感信息融合定位算法研究的重要性，并在此基础上确定了本文的主要研究内容。

第二章：基于多源传感信息融合的前端定位算法研究。在移动机器人前端位姿跟踪过程中，利用轮式编码器、IMU、视觉相机等多种传感器的运动观测信息，以编码器位姿估计改进视觉里程计特征匹配过程，并结合滑动窗口法，通过最小化运动观测残差的方式对移动机器人运动状态向量进行非线性优化，实现了一种紧耦合的多源传感信息融合算法。

第三章：视觉与激光结合的全局定位算法研究。为了结合相机和激光雷达在视觉感知和距离测量方面各自的优势，实现更加全面和准确的感知能力，算法基于视觉与激光结合的方式，在移动机器人定位丢失时，利用信息丰富的视觉快速定位获取先验位姿信息，在 AMCL 定位算法的基础上实现全局定位。

第四章：实验验证与分析。将论文的移动机器人定位算法部署至实验平台，对论文研究内容进行了实验验证，在室内场景下对算法进行了一系列实车测试。实验结果表明，本文采用的基于多源传感信息融合的前端算法在生成轨迹的精度方面有明显提升，为定位系统与导航系统提供良好基础参照；同时大幅提高了移动机器人全局定位的速度与成功率，使移动机器人在定位丢失情境下有更重的重定位能力，保证了移动机器人在复杂环境下的稳定运行。

第五章：总结与展望。对论文研究内容进行了概括总结，并根据算法有待完善的部分与课题相关的发展趋势进行了未来工作展望。

第2章 基于多源传感信息融合的前端定位算法研究

2.1 前端定位算法框架

SLAM 技术主要用来解决移动机器人在封闭空间或者未知环境中的定位以及地图构建的问题^[44], 是移动机器人在未知的场景下通过自主移动来准确完成各种任务的前提, 也是机器人研究领域的重难点之一。其中, SLAM 的前端部分也称为里程计, 主要用于给出移动机器人运动过程中的位姿估计, 确定自身的位置和姿态, 为后续定位建图提供基础, 其精度直接决定了整个 SLAM 算法的定位和建图效果。

采用不同传感器的里程计具有不同的特点: 传统轮式编码器最为常见, 但在轮胎打滑、转向等状态下输出位姿误差较大, 并且存在误差积累, 无法进行长距离精确定位; 惯性测量单元 (inertial measurement unit, IMU) 同样存在误差积累问题, 且在低速、匀速场景下有运动退化的问题^[45]; 视觉里程计以相机图像为输入, 拥有特征信息丰富、实现成本较低等优点, 但精度、鲁棒性等方面受相机成像与环境特征影响。

针对上述各传感器的特点, 本章提出一种融合了轮式编码器、IMU 与视觉相机等多种传感器的移动机器人前端定位算法, 基于轮式编码器的输出位姿改进视觉里程计的跟踪模型, 提高视觉里程计特征匹配成功率; 并建立各传感器的运动位姿观测, 通过基于滑动窗口的非线性优化方法实现对移动机器人运动位姿信息的跟踪估计, 以提高移动机器人前端定位精度。

本章构建的基于多源传感信息融合的前端算法框架如图 2-1 所示。




图 2-1 多源传感信息融合的前端算法框架

算法首先根据轮式编码器、IMU、视觉里程计等传感器的测量模型, 分别确定其在各关键帧时刻下的运动观测。过程中利用轮式编码器的输出预测视觉里程计中

的当前帧位姿，以缩小特征匹配搜索区域；并对 IMU 数据进行预积分处理，解决后续优化过程中的积分计算问题。

其后，算法基于滑动窗口法和非线性优化理论，选取最新的 10 帧关键帧作为优化的滑动窗口，通过舒尔补边缘化消去前置关键帧的影响，并联合各传感器运动观测残差及滑动窗口法引入的边缘化先验残差，采用最小二乘法构建优化函数，通过求解该非线性优化问题，求得各关键帧时刻下的移动机器人运动状态向量估计值，得到前端定位输出位姿，实现移动机器人多源传感信息间的优化融合。

2.2 轮式编码器运动观测

轮式编码器通过采集可得到移动机器人主舵轮速度与转向角信息，需通过相关计算实现关键帧间位姿估计，为多传感信息融合优化提供轮式编码器运动观测。因本文所用实验平台为单舵轮车型，故以单舵轮移动机器人运动学模型^[46]为例，如图 2-2 所示。




图 2-2 单舵轮移动机器人运动学模型

为建立轮式编码器运动观测，以后轮轴中心作为机器人运动中心，忽略车轮与运行表面间的滑动并认为二者为点接触，舵轮回转半径 r 与角速度 ω 可由运动模型瞬心与几何关系给出：

$$r = \begin{cases} l / \tan \theta & (\theta > 0) \\ -l / \tan \theta & (\theta < 0) \end{cases} \quad (2-1)$$

$$\omega = \frac{v \cos \theta}{b / \tan \theta} = \begin{cases} (v \cdot \sin \theta) / b & (\theta > 0) \\ -(v \cdot \sin \theta) / b & (\theta < 0) \end{cases} \quad (2-2)$$

其中， l 为机器人轴距； θ 为主舵轮与车体中心线的夹角，即主舵轮转向角（规定逆时针为正方向，且 $\theta \neq 0$ ）； v 为移动机器人行驶的瞬态线速度，即主舵轮速度。

以 $\mathbf{p}_t = [x_t, y_t, \alpha_t]$ 表示 t 时刻移动机器人的位姿，其与上一关键帧位姿 $\mathbf{p}_{t-1}$ 的关系可由式(2-3)给出：

$$\begin{aligned} x_t &= \begin{cases} x_{t-1} - r \cdot \sin \alpha_{t-1} + r \cdot \sin(\alpha_{t-1} + \omega \cdot \Delta t) & (\theta > 0) \\ x_{t-1} + r \cdot \sin \alpha_{t-1} - r \cdot \sin(\alpha_{t-1} - \omega \cdot \Delta t) & (\theta < 0) \end{cases} \\ y_t &= \begin{cases} y_{t-1} + r \cdot \cos \alpha_{t-1} - r \cdot \cos(\alpha_{t-1} + \omega \cdot \Delta t) & (\theta > 0) \\ y_{t-1} - r \cdot \cos \alpha_{t-1} + r \cdot \cos(\alpha_{t-1} - \omega \cdot \Delta t) & (\theta < 0) \end{cases} \\ \alpha_t &= \begin{cases} \alpha_{t-1} + \omega \cdot \Delta t & (\theta > 0) \\ \alpha_{t-1} - \omega \cdot \Delta t & (\theta < 0) \end{cases} \end{aligned} \quad (2-3)$$

代入式(2-1)与式(2-2)后，整理得：

$$\begin{bmatrix} x_t \\ y_t \\ \alpha_t \end{bmatrix} = \begin{bmatrix} x_{t-1} \\ y_{t-1} \\ \alpha_{t-1} \end{bmatrix} + \begin{bmatrix} -\frac{l}{\tan \theta} \cdot \sin \alpha_{t-1} + \frac{l}{\tan \theta} \cdot \sin \left(\alpha_{t-1} + \frac{v \cdot \Delta t \cdot \sin \theta}{l} \right) \\ \frac{l}{\tan \theta} \cdot \cos \alpha_{t-1} - \frac{l}{\tan \theta} \cdot \cos \left(\alpha_{t-1} + \frac{v \cdot \Delta t \cdot \sin \theta}{l} \right) \\ \frac{v \cdot \Delta t \cdot \sin \theta}{l} \end{bmatrix} \quad (2-4)$$

式(2-4)在上一个关键帧至当前帧之间的编码器测量值上迭代使用，即可得到两帧间的轮式编码器位姿估计。为将轮式编码器运动观测信息加入基于关键帧的多传感信息融合过程，算法通过线性插值的方式将编码器采样时刻与各视觉关键帧对齐。记 t 时刻视觉关键帧的前后两帧轮式编码器运动观测为 $\mathbf{p}_{t_1}$ 与 $\mathbf{p}_{t_2}$ ，可近似得到 t 时刻的轮式编码器运动观测为：

$$\mathbf{p}_t = \frac{(t_2 - t) \mathbf{p}_{t_1} + (t - t_1) \mathbf{p}_{t_2}}{t_2 - t_1} \quad (2-5)$$

2.3 视觉里程计运动观测

视觉传感器通过相机内部透镜实现对光线的聚焦和成像，将三维世界中的坐标点投影到以像素为单位的二维图像平面上，从而将三维环境信息转换为图像像素矩阵。在视觉传感器中，图像中的像素对应表示三维世界中的一个点，而像素之间的距离和位置则反映对应路标点之间的相对位置和距离信息。在相机成像模型中，涉及到的坐标系有对应图像像素矩阵的像素坐标系，以相机光心为原点的相机坐标系，以及表示地图中三维点的世界坐标系。

针孔模型是最为常用且有效的成像模型，如图 2-3 所示^[47]，以 $O-x-y-z$ 表示相机坐标系，透镜的位置即为相机的光心 O ，习惯上 z 轴指向相机的正前方， x 轴指向相机右方， y 轴正方向竖直向下。 $O'-x'-y'$ 表示物理成像平面，位于光心后方，

物理成像平面到小孔之间的距离 $O-O'$ 即为焦距，用 f 表示。世界坐标系中的一点 P 经过光心投影，在平面 $O'-x'-y'$ 上的成像点用 P' 表示。




图 2-3 针孔模型的成像原理

在相机坐标系下，设点 P 坐标为 $[X, Y, Z]$ ，点 P' 坐标为 $[X', Y', Z']$ ，如图 2-3 所示，点 P 与点 P' 间的关系可由相似关系得到：

$$\frac{Z}{f} = -\frac{X}{X'} = -\frac{Y}{Y'} \quad (2-6)$$

式中负号表示成像呈倒立状态，整理后可得：

$$X' = f \frac{X}{Z} \quad (2-7)$$

$$Y' = f \frac{Y}{Z} \quad (2-8)$$

在视觉定位算法中，为处理相机最终输出的像素矩阵，需要在成像平面上对图像信息进行采样与量化，将物理成像平面一点 P' 转换到像素平面坐标。在物理成像平面 $O'-x'-y'$ 的同一平面上固定像素平面 $o-u-v$ ，其原点 o 置于图像左上角， u 轴与 x' 轴平行，表示图像的行坐标， v 轴与 y' 轴平行，表示图像的列坐标，则像素坐标系与物理成像坐标系的关系可由原点的平移与坐标轴的尺度比例缩放表示。

记物理成像平面至像素坐标系原点 o 的平移为 $[c_x, c_y]^T$ ，像素坐标轴缩 $u-v$ 的缩放为 α 与 β 倍，可得物理成像平面到像素坐标系的变换为：

$$\begin{cases} u = \alpha X' + c_x \\ v = \beta Y' + c_y \end{cases} \quad (2-9)$$

综上所述，记 αf 为 f_x ， βf 为 f_y ，则有：

$$\begin{cases} u = f_x \frac{X}{Z} + c_x \\ v = f_y \frac{Y}{Z} + c_y \end{cases} \quad (2-10)$$

以矩阵形式表示 P 点的世界坐标到像素坐标的投影关系，如式(2-11)所示。

$$ZP_{uv} = Z \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = KP_c = K(RP_w + t) = KTP_w \quad (2-11)$$

其中， P_{uv} 表示像素平面齐次坐标， P_c 、 P_w 分别表示三维点 P 在相机坐标系下与世界坐标系下的坐标； K 称为相机内参数矩阵，表示相机坐标系至像素坐标系的变换关系，通过传感器标定得到； T 则为外参矩阵，表示移动机器人运动轨迹，即为视觉里程计的运动观测目标。

实际应用中相机使用透镜改变光学传播轨迹，由于镜头的物理特性引起相机畸变，针孔投影模型并非严格成立。光线在经过镜头时，其成像模型与透镜的曲面不完全吻合，或相机镜头的结构不完美，导致成像出现偏差，即图像中的物体形状和尺寸不再准确反映真实物体的形状和尺寸。

如图 2-4 所示，相机畸变主要分为径向畸变和切向畸变两种类型。径向畸变是由相机透镜形状不规则造成的，使得直线在成像后变曲，离图像中心点越远的位置影响越大。切向畸变则是由于透镜和成像平面之间不平行而引起的，会使得图像中的物体产生一定程度的形变。为了消除这些畸变的影响，需要进行畸变校正，使得图像中的物体能够更准确地被测量和识别。




图 2-4 相机畸变模型

根据畸变模型，计算归一化平面上投影位置发生畸变后的坐标，如式(2-12)所示。

$$\begin{aligned} x_{\text{distorted}} &= x(1+k_1r^2+k_2r^4+k_3r^6)+2p_1xy+p_2(r^2+2x^2) \\ y_{\text{distorted}} &= y(1+k_1r^2+k_2r^4+k_3r^6)+p_1(r^2+2y^2)+2p_2xy \end{aligned} \quad (2-12)$$

其中， r 表示平面任一点 p 与坐标系原点之间的距离， k_1 、 k_2 、 k_3 与 p_1 、 p_2 为畸变系数，分别表示径向畸变与切向畸变。在实际应用中，根据相机成像的畸变类型与程度，以及视觉定位算法的精度要求，可部分选取其中的畸变参数进行校正。

如 1.2.2 节中的图 1-5 所示，视觉里程计采用与 ORB-SLAM 跟踪线程相似的结构：对输入图像提取 ORB 特征，并根据时间、空间与共视特征点数目等指标选取关键帧，在关键帧与当前帧间进行特征点匹配，再对具有对应关系的特征点对进行 PnP（Perspective-n-Point）解算^[48-49]得到视觉里程计的位姿估计。

ORB-SLAM 采用恒速模型跟踪、参考关键帧跟踪、重定位跟踪等方式确定特征点匹配区域，搜索匹配点的过程在图像坐标系下执行，特征匹配过程如图 2-5 所示。其中算法在多数情况下采用恒速模型跟踪，即基于短时间内相机处于匀速运动状态的假设，用上一帧的位姿和速度来对当前帧初始位姿进行估计，根据特征点的重投影位置确定匹配搜索区域；在刚完成重定位或者恒速模型跟踪失败时，由于算法没有速度信息，则利用参考关键帧的信息跟踪；重定位跟踪则在跟踪丢失时使用，利用到了相似候选帧的信息。




图 2-5 特征匹配过程

而在本文多传感器融合算法中，由于整合了轮式编码器信息，视觉里程计在特征匹配前即可获取机器人初始位姿的先验信息，因此，算法优先采用利用编码器位姿跟踪的方式估计控制匹配搜索区域。

以针孔相机成像模型为例,可将一个局部地图点 $\mathbf{P}_w$ 投影到轮式编码器估测的当前帧位置,得到一个像素平面上的 2D 位置 $\mathbf{u}$ 。

$$\mathbf{u} = \mathbf{K} \hat{\mathbf{T}}_{r_k}^c \mathbf{T}_k \mathbf{P}_w \quad (2-13)$$

其中, $\mathbf{K}$ 表示相机内参矩阵, $\mathbf{T}_k$ 表示上一关键帧世界坐标系到相机坐标系的变换矩阵, $\hat{\mathbf{T}}_{r_k}^c$ 表示由轮式编码器求解的关键帧到当前帧的位姿估计。

以 $\mathbf{u}$ 为中心,特征匹配搜索过程如图 2-6 所示,搜索的范围是以投影点 $\mathbf{u}$ 为中心,3L 为半径的圆内的像素点。补偿参数 L 用于控制搜索范围的大小,L 的初始值本文设置为 1,如果没有找到匹配的特征点,则增大 L 来逐步扩大搜索范围,最大增加到 3 来搜索匹配的特征。如果仍未找到匹配的特征点,则说明编码器位姿估计可能不准确,仍采用恒速模型跟踪等方式来确定匹配区域。




图 2-6 视觉里程计特征匹配搜索过程

确定特征匹配关系后,对特征点对进行 PnP 求解,即可得到相机运动估计,为移动机器人多传感信息融合过程提供视觉运动观测信息。以 EPnP 算法为例,该算法是一种快速而精确的相机姿态恢复方法,能够从至少 4 个已知世界坐标点和它们在图像上的对应点求解相机的位姿。

假设已经确定了至少 4 个世界坐标系中的点和它们在图像上的对应点,在利用 RANSAC 等方法剔除错误匹配后,通过这些点,得到归一化相机坐标系中的 3D 点(即将其投影到归一化平面)和 2D 点(对应于图像上的像素坐标),从参考点质心及数据的三个主方向上选取 4 个不共面的控制点 $\mathbf{c}_j^w$,使得世界坐标系下 3D 点的坐标 $\mathbf{P}_i^w$ 可以表示为对应控制点坐标的线性组合:

$$\mathbf{P}_i^w = \sum_{j=1}^4 \alpha_{ij} \mathbf{c}_j^w, \sum_{j=1}^4 \alpha_{ij} = 1 \quad (2-14)$$

记 w_i 为投影尺度系数, $\mathbf{K}$ 为相机内参矩阵, $\mathbf{P}_i^c$ 为相机坐标系下 3D 参考点对应的 2D 投影坐标, 根据相机透视投影关系构建约束, 有:

$$w_i \begin{bmatrix} \mathbf{u}_i \\ 1 \end{bmatrix} = \mathbf{K} \mathbf{P}_i^c = \mathbf{K} \sum_{j=1}^4 \alpha_{ij} \mathbf{c}_j^c = \begin{bmatrix} f_x & 0 & u_0 \\ 0 & f_y & v_0 \\ 0 & 0 & 1 \end{bmatrix} \sum_{j=1}^4 \alpha_{ij} \begin{bmatrix} x_j^c \\ y_j^c \\ z_j^c \end{bmatrix} \quad (2-15)$$

将矩阵展开写成等式右边为 0 的表达式, 化简后每个点对可以得到 2 个方程,

$$\begin{cases} \sum_{j=1}^4 \alpha_{ij} f_x x_j^c + \alpha_{ij} (u_c - u_i) z_j^c = 0 \\ \sum_{j=1}^4 \alpha_{ij} f_y y_j^c + \alpha_{ij} (v_c - v_i) z_j^c = 0 \end{cases} \quad (2-16)$$

其中, $i=1, \dots, n$ 表示点对的数目。考虑 4 组匹配特征点, 可得线性方程组

$$\mathbf{M} \mathbf{x} = \mathbf{0} \quad (2-17)$$

式中, $\mathbf{M}$ 为 $2n \times 12$ 的矩阵, 待求的未知数 $\mathbf{x}$ 是 12 个相机坐标系下控制点坐标 $\{(x_j^c, y_j^c, z_j^c)\}, j=1, \dots, 4$, 其可表示为

$$\mathbf{x} = \sum_{i=1}^N \beta_i \mathbf{v}_i \quad (2-18)$$

其中, $\mathbf{v}_i$ 是 $\mathbf{M}$ 的零奇异值对应的右奇异向量, 其维度为 12×1 。

为求解式(2-17), 通过构建 $\mathbf{M}^T \mathbf{M}$ 组成方阵, 求解其特征值和特征向量, 特征值为 0 的特征向量即为 $\mathbf{v}_i$ 。由于控制点的刚体结构不变性, 即在相机坐标系和世界坐标系下两个点的点距恒定, 有

$$\|\mathbf{c}_i^c - \mathbf{c}_j^c\|^2 = \|\mathbf{c}_i^w - \mathbf{c}_j^w\|^2 = \left\| \sum_{k=1}^N \beta_k \mathbf{v}_k^{[i]} - \sum_{k=1}^N \beta_k \mathbf{v}_k^{[j]} \right\|^2 \quad (2-19)$$

基于上式, 可构造累积平方误差函数, 通过高斯牛顿法优化, 调整两个坐标系下控制点间距的差 β_k , 使得其误差最小, 如式(2-20)所示。

$$f(\beta_k) = \sum_{(i,j \text{ s.t. } i < j)} (\|\mathbf{c}_i^c - \mathbf{c}_j^c\|^2 - \|\mathbf{c}_i^w - \mathbf{c}_j^w\|^2) \quad (2-20)$$

通过求解式(2-20)并代入式(2-15), 可计算得到相机坐标系下投影点坐标 $\mathbf{P}_i^c$, 完成 PnP 求解。在此基础上, 进一步计算当前时刻相机坐标系相对于世界坐标系的变换矩阵, 即可得到视觉里程计运动观测。

2.4 IMU 运动观测

由于 IMU 采样频率较高，两帧间数据量较大，为了避免后续优化过程中每一次迭代都要重新积分，本文对 IMU 输出数据采取预积分处理，其目的是将每次优化迭代时不变的项提出，以在迭代优化时快速计算当前帧运动估计。

根据 IMU 误差模型式(2-21)、PVQ 一阶导数模型式(2-22)与离散时间下的 IMU 积分模型式(2-23)，将相对世界坐标系的旋转转化为相对上一帧时 IMU 坐标系的旋转。

$$\begin{cases} \hat{a}_b = q_{bw}(a^w + g^w) + b_a + n_a \\ \hat{\omega}_b = \omega_b + b_\omega + n_\omega \end{cases} \quad (2-21)$$

$$\begin{cases} \dot{p}_{wb_t} = v_t^w \\ \dot{v}_t^w = a_t^w \\ \dot{q}_{wb_t} = q_{wb_t} \otimes \begin{bmatrix} 0 \\ \frac{1}{2}\omega_{b_t} \end{bmatrix} \end{cases} \quad (2-22)$$

$$\begin{cases} p_{wb_{k+1}} = p_{wb_k} + v_k^w \Delta t + \frac{1}{2} a \Delta t^2 \\ v_{k+1}^w = v_k^w + a \Delta t \\ q_{wb_{k+1}} = q_{wb_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \Delta t \end{bmatrix} \end{cases} \quad (2-23)$$

对于离散形式，算法采用递推的方式从关键帧 k 的状态传播到关键帧 $k+1$ 的状态，其间的 IMU 测量时刻记为 i ，则有：

$$q_{wb_k} = q_{wb_i} \otimes q_{b_i b_k} = q_{wb_{i+1}} \otimes q_{b_{i+1} b_k} \quad (2-24)$$

根据预积分方法，得到离散时间下的预积分单步 PVQ 传播如下：

$$\begin{cases} \alpha_{b_k} b_{i+1} = \alpha_{b_k} b_i + \beta_{b_k} b_i \delta t + \frac{1}{2} a \delta t^2 \\ \beta_{b_k} b_{i+1} = \beta_{b_k} b_i \delta t + a \delta t \\ \gamma_{b_k} b_{i+1} = \gamma_{b_k} b_i \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} \end{cases} \quad (2-25)$$

式中, δt 为两 IMU 测量值之间的时间差。根据中值法, 有:

$$\begin{aligned} a &= \frac{1}{2} [q_{b_k b_i} (a_{b_i} - b_{a_i}) + q_{b_k b_{i+1}} (a_{b_{i+1}} - b_{a_{i+1}})] \\ \omega &= \frac{1}{2} (\omega_{b_i} - b_{\omega_i} - \omega_{b_{i+1}} - b_{\omega_{i+1}}) \end{aligned} \quad (2-26)$$

据此可得到 IMU 在 k 时刻与 $k+1$ 时刻的离散时间下的关键帧间运动估计的积分形式为:

$$\begin{bmatrix} p_{wb_{k+1}} \\ v_{k+1}^w \\ q_{wb_{k+1}} \\ b_{a_{k+1}} \\ b_{\omega_{k+1}} \end{bmatrix} = \begin{bmatrix} p_{wb_k} + v_k^w \Delta t - \frac{1}{2} g^w \Delta t^2 + q_{wb_k} \otimes \alpha_{b_k} b_{k+1} \\ v_k^w - g^w \Delta t + q_{wb_k} \otimes \beta_{b_k b_{k+1}} \\ q_{wb_k} \otimes \gamma_{b_k b_{k+1}} \\ b_{a_k} \\ b_{\omega_k} \end{bmatrix} \quad (2-27)$$

其中, p 、 v 、 q 分别代表位移、速度与旋转, 上下标 w 表示世界坐标系, b 表示本体坐标系, b_a 与 b_ω 为加速度与角速度的偏置。

2.5 多传感器信息融合

2.5.1 最小二乘问题构建

实现移动机器人状态估计的主流方法有滤波器方法和非线性优化方法。其中, EKF 方法形式简洁、应用广泛, 在早期移动机器人的状态估计问题中, 该方法占据了很长一段时间的主导地位, 但 EKF 存在一些局限性, 比如它基于马尔可夫性的假设, 在非线性情况存在较大误差, 且不适用于大型场景等; 而非线性优化方法能综合考虑所有历史数据, 且能更好地适用于非线性情况, 因此在较新的 SLAM 算法中, 通常采用求解非线性最小二乘问题的方式进行状态估计^[47]。

因此为实现多源传感信息融合的移动机器人前端处理, 本章采用非线性优化融合的方式, 根据各传感器采集的机器人运动观测信息, 对观测残差之和进行最小二乘优化, 以完成对移动机器人位置、姿态等运动状态信息的估计。其中, 传感器的运动观测残差是指多传感信息融合过程中, 各传感器下的机器人运动状态观测值与运动状态估计值之间的差值; 而优化的目标即是调整状态估计值, 以使得残差函数最小。

在多传感信息融合过程中, 移动机器人运动观测信息中存在较大的信息量。随着移动机器人行程的增加, 关键帧数量及其运动观测的复杂度也会逐渐增长, 为了

避免优化的规模不断地扩大，本文采用滑动窗口法以保证优化问题运算过程的实时性。

如图 2-7 所示，选取各传感器最新获取的 10 帧关键帧作为移动机器人运动观测滑动窗口，滑动窗口随机器人行程在关键帧序列中移动，并对移除的关键帧数据进行边缘化，引入滑动窗口边缘化先验残差^[50]；同时利用滑动窗口中单目视觉、IMU 及轮式编码器的运动观测量确定优化残差项，将各项残差之和作为最小二乘问题优化的目标。




图 2-7 移动机器人运动观测滑动窗口示意图

首先，确定待优化变量为移动机器人在滑动窗口各关键帧处的运动状态向量 χ ：

$$\chi = [\mathbf{x}_N, \mathbf{x}_{N-1}, \dots, \mathbf{x}_{N-9}, \lambda_l, \lambda_{l+1}, \dots, \lambda_{l+M}]^T \quad (2-28)$$

其中，

$$\mathbf{x}_k = [p_{B_k}^W, v_{B_k}^W, q_{B_k}^W, b_{a_k}, b_{\omega_k}, b_{v_k}, b_{\psi_k}]^T, k \in [N, N-9] \quad (2-29)$$

其中， N 为当前关键帧对应序列， M 为滑动窗口内所观测到的路标点数量； $\mathbf{x}_k$ 表示第 k 帧的位姿状态，此处取滑动窗口中 IMU 在关键帧 B_k 下相对世界坐标系 W 的位置 $p_{B_k}^W$ ，运动速度 $v_{B_k}^W$ ，姿态四元数 $q_{B_k}^W$ ，以及加速度计偏置与陀螺仪偏置 b_{a_k} 、 b_{ω_k} ，轮式编码器速度与角速度测量偏差 b_{v_k} 、 b_{ψ_k} ； λ_l 为视觉里程计观察到的路标点 l 的逆深度，其值等于 l 在相机坐标系下的深度 z_l 的倒数。

移动机器人运动观测的总体残差项，由视觉里程计重投影误差 $\mathbf{r}_C$ 、IMU 运动观测残差 $\mathbf{r}_B$ 、轮式编码器运动观测残差 $\mathbf{r}_O$ 及边缘化先验残差 $\mathbf{r}_P$ 四部分构成。因此移动机器人运动观测残差关于运动状态优化向量 χ 的非线性最小二乘问题可以表示为：

$$\min_{\chi} \left\{ \sum_{(i,j) \in C} \left\| \mathbf{r}_C \left(\hat{\mathbf{z}}_{C_i(l)}, \chi \right) \right\|_{\mathbf{P}_{C_i(l)}^{C_j}}^2 + \sum_{k \in B} \left\| \mathbf{r}_B \left(\hat{\mathbf{z}}_{B_{k+1}}, \chi \right) \right\|_{\mathbf{P}_{B_k}^{B_{k+1}}}^2 + \sum_{k \in O} \left\| \mathbf{r}_O \left(\hat{\mathbf{z}}_{O_{k+1}}, \chi \right) \right\|_{\mathbf{P}_{O_k}^{O_{k+1}}}^2 + \left\| \mathbf{r}_P - \mathbf{J}_{\chi}^P \chi \right\|^2 \right\} \quad (2-30)$$

其中, $\hat{\mathbf{z}}_{C_i(l)}^{C_j}$ 表示由视觉关键帧 C_i 中提取到的视觉特征 l 得出的关键帧 C_i 与 C_j 之间的视觉里程计位姿估计, $\hat{\mathbf{z}}_{B_k}^{B_{k+1}}$ 表示 IMU 关键帧 B_k 与 B_{k+1} 间的 IMU 运动估计, $\hat{\mathbf{z}}_{O_k}^{O_{k+1}}$ 表示轮式编码器关键帧 O_k 与 O_{k+1} 间的位姿估计, $\mathbf{J}_\chi^p$ 表示滑动窗口先验残差 $\mathbf{r}_p$ 关于移动机器人运动状态优化向量 χ 的雅可比矩阵, $\mathbf{P}_{C_i(l)}^{C_j}$ 、 $\mathbf{P}_{B_k}^{B_{k+1}}$ 、 $\mathbf{P}_{O_k}^{O_{k+1}}$ 分别为多传感信息优化融合过程中表示各运动观测信息可信度的视觉里程计误差协方差矩阵、IMU 误差协方差矩阵及轮式编码器误差协方差矩阵。

2.5.2 残差计算与优化求解

为求解式(2-30)中的最小二乘优化问题, 需对其中的各部分残差项进行表示。




图 2-8 重投影误差示意图

视觉里程计运动观测残差可直接使用其重投影误差表示, 如图 2-8 所示。对于第 i 帧图像中的某特征点 p_1 反投影到世界坐标系, 其对应空间点 P ; 再根据视觉里程计估计结果获得第 j 帧图像在空间中位姿, 将点 P 重投影到该图像, 得到像素位置的预测值 $\hat{p}_2$; 再通过特征点的匹配, 在第 j 帧图像中找到与 p_1 匹配的特征点, 即为真实的像素位置观测值 p_2 。 $\hat{p}_2$ 与 p_2 在像素坐标系间的差值即为重投影误差 $\mathbf{r}_C(\hat{\mathbf{z}}_{C_i(l)}^{C_j}, \chi)$, 由下式给出:

$$\mathbf{r}_C(\hat{\mathbf{z}}_{C_i(l)}^{C_j}, \chi)_c = \begin{bmatrix} \frac{x_{c_j}}{z_{c_j}} - u_{c_j} \\ \frac{y_{c_j}}{z_{c_j}} - v_{c_j} \end{bmatrix} = \mathbf{u}_i - \frac{1}{s_i} K \exp(\xi^\wedge) \mathbf{P}_i \quad (2-31)$$

式中, u_{c_j} 和 v_{c_j} 为特征点位置观测值在像素坐标系的坐标, $\exp(\xi^\wedge)$ 为世界坐标系到像素坐标系的变换矩阵。

式(2-4)中轮式编码器关键帧 O_k 与 O_{k+1} 间运动观测信息传递公式为:

$$\begin{cases} R_W^{O_k} p_{O_{k+1}}^W = R_W^{O_k} p_{O_k}^W \\ q_{O_{k+1}}^W = q_{O_k}^W \otimes \gamma_{O_k}^{O_{k+1}} \\ b_{v_{k+1}} = b_{v_k} \\ b_{\psi_{k+1}} = b_{\psi_k} \end{cases} \quad (2-32)$$

在多传感器信息融合时, 该运动观测信息将会产生优化增量, 由此可得轮式编码器关键帧 O_k 与 O_{k+1} 间的运动观测残差 $r_o(\hat{z}_{O_k}^{O_{k+1}}, \chi)$ 为:

$$r_o(\hat{z}_{O_k}^{O_{k+1}}, \chi) = \begin{bmatrix} r_p(\hat{z}_{O_k}^{O_{k+1}}, \chi) \\ r_q(\hat{z}_{O_k}^{O_{k+1}}, \chi) \\ r_{b_v}(\hat{z}_{O_k}^{O_{k+1}}, \chi) \\ r_{b_\psi}(\hat{z}_{O_k}^{O_{k+1}}, \chi) \end{bmatrix} = \begin{bmatrix} R_W^{O_k} (p_{O_{k+1}}^W - p_{O_k}^W) - \alpha_{O_k}^{O_{k+1}} \\ 2 \left[(\rho_{O_k}^{O_{k+1}})^{-1} \otimes (q_{O_k}^W)^{-1} \otimes q_{O_{k+1}}^W \right]_{v_{yz}} \\ b_{v_{k+1}} - b_{v_k} \\ b_{\psi_{k+1}} - b_{\psi_k} \end{bmatrix} \quad (2-33)$$

式中, $r_p(\hat{z}_{O_k}^{O_{k+1}}, \chi)$ 、 $r_q(\hat{z}_{O_k}^{O_{k+1}}, \chi)$ 、 $r_{b_v}(\hat{z}_{O_k}^{O_{k+1}}, \chi)$ 、 $r_{b_\psi}(\hat{z}_{O_k}^{O_{k+1}}, \chi)$ 表示移动机器人本体坐标系下为 O_k 帧至 O_{k+1} 帧之间的残差, 依次为位置残差项、姿态残差项、速度测量偏差残差项及角速度测量偏差残差项。

根据式(2-33), 在滑动窗口中逐一计算相邻关键帧间轮式编码器的运动观测残差, 即可确定滑动窗口中轮式里程计运动观测总残差 $\sum_{k \in O} \left\| r_o(\hat{z}_{O_k}^{O_{k+1}}, \chi) \right\|_{P_{O_k}^{O_{k+1}}}^2$ 。

同理, 根据 IMU 关键帧间运动估计的预积分, 可构建离散时间的 IMU 预积分残差 $r_B(\hat{z}_{B_k}^{B_{k+1}}, \chi)$ 表示为:

$$r_B(\hat{z}_{B_k}^{B_{k+1}}, \chi) = \begin{bmatrix} r_p \\ r_v \\ r_q \\ r_{b_a} \\ r_{b_\omega} \end{bmatrix} = \begin{bmatrix} q_{b_k u} (p_{ab_{k+1}} - p_b b_k - v_k^u \Delta t + \frac{1}{2} g^w \Delta t^2) - \alpha_{b_k b_{k+1}} \\ q_{b_k w} (v_{k+1} - v_k^w + g^w \Delta t) - \beta_{b_k b_{k+1}} \\ 2[\gamma_{b_{k+1} b_k} \otimes (q_{b_k w} \otimes q_{ab_{k+1}})]_{xyz} \\ b_{a_{k+1}} - b_{a_k} \\ b_{\omega_{k+1}} - b_{\omega_k} \end{bmatrix} \quad (2-34)$$

在多传感器信息中, 将视觉里程计中满足时间、空间与共视特征点数目等指标要求的当前帧图像选为视觉关键帧, 同时将 IMU 与轮式编码器的同一测量帧也选作

其关键帧。在利用滑动窗口法进行非线性优化时,应保持窗口内关键帧数量为 10 帧。但在移除旧的变量,即将滑动窗口中最早提取的各传感器信息关键帧移出滑动窗口时,变量间仍然存在多项约束,这些约束将会随着更新在新的线性化点下进行求解计算,这导致先验的雅可比矩阵的线性化点与新残差的线性化点不同,以带来错误的估计。因此,为定量考虑被边缘化的量给其余变量带来了什么信息,引入边缘化先验残差,以保留各传感器的先验约束信息。由此,可在不影响窗口内优化求解效率的同时,将被舍弃的状态信息通过先验的方式加入最小二乘优化问题,同时使得问题的规模不会随时间的推移而增大。

若忽略滑动窗口先验约束,则滑动窗口中的各传感器的运动观测残差优化公式可表示为

$$H_s \Delta \chi = b_s \quad (2-35)$$

式中, H_s 与 b_s 分别为滑动窗口中各传感信息运动观测残差优化的总海塞矩阵及总残差向量。

其分解形式为:

$$\begin{bmatrix} H_{s_1} & H_{s_2} \\ H_{s_2}^T & H_{s_3} \end{bmatrix} \begin{bmatrix} \Delta \chi_1 \\ \Delta \chi_2 \end{bmatrix} = \begin{bmatrix} b_{s_1} \\ b_{s_2} \end{bmatrix} \quad (2-36)$$

式中, $\Delta \chi_1$ 为将移除关键帧对应的运动状态优化向量 χ 的增量, $\Delta \chi_2$ 为保留于滑动窗口中的关键帧对应的 χ 增量。

随着移动机器人行程的增加,滑动窗口不断在关键帧序列中移动,并对被移除的关键帧变量进行边缘化操作。在通过舒尔补矩阵消元处理后,可求得滑动窗口先验约束对应的海塞矩阵 H_p 和残差向量 b_p 如下式。

$$\begin{cases} H_p = H_{s_3} - (H_{s_2})^T (H_{s_1})^{-1} H_{s_2} \\ b_p = b_{s_2} - (H_{s_2})^T (H_{s_1})^{-1} b_{s_1} \end{cases} \quad (2-37)$$

每次滑动窗口边缘化过程中,根据这一 H_p 、 b_p 矩阵反推出一个先验残差 r_p 和对应雅可比 J_χ^p ,按式(2-30)中的 $\|r_p - J_\chi^p \chi\|$ 项构建边缘化先验残差,即可消除移除关键帧的影响,使其约束信息保留在新的滑动窗口中,从而确保计算复杂度的同时保证运动状态估计的完整性。

确定运动状态优化向量与残差项后,将其平方和作为整体残差,构建最小二乘问题,即可对式(2-30)进行优化求解,优化过程可通过 G2O 图优化的方式实现。

G2O 是一种基于 C++ 编程语言的非线性优化通用框架,这种方法已经被广泛应用于机器人和自动驾驶等领域的优化问题,取得了显著的效果。在使用 G2O 求解非线性优化问题时,首先需要定义一个图 (graph),并在图中用顶点 (Vertex) 表示优化变量,用边 (Edge) 表示误差项,从而直观地表示优化问题。

在前端定位算法中,顶点代表相机的位姿或 IMU 的状态,而边用于连接顶点,代表顶点间约束,即表示视觉、IMU 或轮式编码器测量值与相邻节点之间的约束关系。从而,在前端定位算法中,我们可以将非线性优化问题建模为一个带有相机和 IMU 节点的图优化问题,如图 2-9 所示。每个节点与它的前置或后续节点之间连接有相应的边,其中三角形、圆形顶点分别对应关键帧与地图点、运动状态向量,蓝色线对应运动方程,红色线对应观测方程。




图 2-9 前端定位算法的图优化问题

在将问题建模为图后,就可以使用 G2O 库对这个图进行优化。优化的过程是通过迭代的方式进行的,每次迭代会计算出一个更新后的节点状态,使得误差(代价函数)最小化。G2O 使用列文伯格-马夸尔特 (Levenberg-Marquardt) 法进行优化,它是一种针对非线性最小二乘问题的迭代优化算法,能够有效地处理优化融合问题中的非线性误差项。

通过使用 G2O 对多传感器信息融合问题进行求解,优化移动机器人在滑动窗口各关键帧处的运动状态向量 χ 以最小化观测残差,可以得到一个最优的机器人运动状态估计,即为前端定位算法输出的位姿跟踪结果。

2.6 小结

本章在移动机器人前端定位过程中,以编码器位姿估计改进视觉里程计特征匹配过程,分别得到了轮式编码器、IMU、视觉相机等多种传感器的运动观测信息。随后结合滑动窗口法,通过最小化运动观测残差的方式,对移动机器人运动状态构建了最小二乘优化问题。通过对各传感器运动观测的残差项与滑动窗口法引入的边

缘化先验残差进行推导，最后进行非线性优化求解，实现了一种紧耦合的多源传感信息融合算法，进而完成高精度的运动跟踪和位姿估计，有效提高了移动机器人 SLAM 中前端定位的定位精度。

前端里程计信息不仅用于在导航系统中进行移动机器人位姿跟踪和地标的更新，同时也用于在全局定位中获取绝对位置测量结果。本章的研究内容基于多源传感信息融合改进了前端定位算法，以获得更好的可靠性，为后续全局定位算法与移动机器人 SLAM 系统提供了可靠参照。

第3章 视觉与激光结合的全局定位算法研究

3.1 算法理论基础

移动机器人全局定位通常发生于初始位姿未知或定位丢失等情况下，指机器人通过传感器获取观测信息，确定自身在已知全局地图中的位置和姿态。例如，机器人在初始启动或者遇到意外情况而被强制重启时，就需要获取机器人的初始位姿以完成后续位姿跟踪；或由于导航过程中被搬移、外部碰撞等外部因素发生定位失效，导致机器人位置突然发生变化而里程计无法给出相应信息，使得原本依赖于位姿连续变化的前端位姿跟踪算法无法正常工作，这种情况也被称为机器人“绑架”问题^[51]。准确的全局定位信息是确保移动机器人导航系统在复杂场景下正常工作的关键环节之一。

移动机器人全局定位技术面临着多种挑战，如缺乏先验知识、环境变化、传感器噪声、数据关联困难等，其中算法的关键问题在于，如何表征传感器获取的局部信息、确定匹配搜索区域并与全局地图进行匹配。激光雷达不受光线变化影响，且测量精度高，并综合考虑成本因素，许多全局定位算法采用单线激光雷达作为传感信息输入。在此类算法中，通常通过构建占用栅格地图完成定位导航功能，即将地图栅格化，并根据激光雷达测量值按概率将栅格分为占用、空闲与未知状态，从而描述全局地图信息与传感器测得的局部环境信息。

在此类方法中，蒙特卡洛定位法是基于粒子滤波的定位算法，是一种非参数滤波方法，其过程如图 3-1 所示。它通过对状态空间进行采样，使用一组离散的状态粒子来表示机器人可能的位置和姿态的概率分布。随着机器人行进，传感器会提供新的观测数据，粒子通过根据运动模型进行更新，并且将计算每个粒子的权重，以反映其对观测数据的拟合程度，用来计算机器人在当前时刻的位置概率分布。通过重采样操作，粒子被更新为更准确的状态，在迭代后通过采样表示后验。




图 3-1 蒙特卡洛定位算法流程

自适应蒙特卡洛算法在 MCL 的基础上进行改进。算法首先通过库尔贝克-莱布勒散度（Kullback-Leibler Divergence, KLD）^[52]，在每次更新时根据粒子权重的分布计算系统所需要的粒子数目，如果信息量超过预设的阈值，就会进行重采样，以

达到动态调整粒子数目的效果，从而在保证重采样后粒子数量不变的情况下，提高粒子的采样效率，提高 MCL 算法的计算速度。其次，AMCL 算法利用自适应重采样方法^[53]，根据实际情况调整粒子的数量和位置，并通过增加随机粒子到粒子集合的方式避免粒子的错误收敛，以防止算法因过度采样导致粒子退化。此外，由于大量的精细采样粒子与定位的实时性要求是相悖的，为在实现高精度定位的同时避免此问题，常结合激光点云匹配算法求取两点云之间精确的旋转和平移变换，对 AMCL 定位进行优化。

AMCL 算法是目前激光定位领域中的主流算法，其综合表现在理论研究和工程实践中得到了普遍认可，在移动机器人全局定位算法中被广泛采用。但在实际定位过程中，由于粒子滤波算法需要在全局地图范围内随机分布粒子，算法通常需要经过足够多的运动以获取传感信息，才能使得粒子成功收敛，使得算法定位时间普遍过长，难以满足移动机器人在发生定位丢失等情境下快速定位的要求；此外，在环境特征相似的场景中，粒子的似然域模型相似度较高，粒子群可能难以收敛或收敛于错误位置。

此外，采用单线激光雷达的全局定位算法也存在其他问题。例如单线激光雷达无法区分不同高度的物体，也无法获取物体的颜色、纹理等特征，导致在对整个地图进行搜索时，易发生误匹配或全局搜索时间过长的问題，仅适合在固定帧间的点云进行匹配^[54]。而视觉传感器不仅能够通过双目、RGB-D 等方式获取绝对尺度信息，还能够获取物体的颜色、纹理、形状等特征，这些特征可以用来构建词袋模型，更快速正确地检测闭环^[55]，适合做全局的匹配定位；但基于视觉的定位算法需要复杂的图像处理和计算机视觉算法，所形成的稀疏特征点云地图不能反映环境中物体的几何形状和占据状态，不适合用于导航与避障。

因此，本章以 AMCL 算法为基础，结合视觉方法，对全局定位算法加以改进，使得算法在保证定位精度的同时，提高准确率和效率。

3.2 全局定位算法框架

本章提出了一种视觉与激光结合的全局定位方法，在建图过程中利用视觉与激光 SLAM，分别建立特征点地图与激光栅格地图，并建立其位姿关系映射与视觉关键帧数据库。在全局定位过程中，利用当前图像与关键帧数据库进行词袋模型比对，并根据相似关键帧位姿，通过求解 PnP 问题解算出当前的相机位姿，根据位姿映射得出激光栅格地图中的粗定位信息，作为 AMCL 算法的先验信息，从而缩小了候选地图搜索区域，实现快速、准确的全局定位。

视觉与激光结合的全局定位算法框架如图 3-2 所示。




图 3-2 全局定位算法框架

首先，在算法建图过程中，在使用单线激光雷达 SLAM 建立二维占用栅格地图的基础上，同时利用 RGB-D 相机开展视觉 SLAM，建立视觉特征点云地图，根据时间、空间与共视特征点数目等指标选取关键帧，并将两种算法的时间戳做同步处理，记录建图过程中二者的位姿信息。根据相机与激光雷达之间的外参矩阵及位姿信息，可将特征点地图与激光栅格地图进行对齐，得到两种地图之间的位姿映射；同时利用 DBoW 词袋库，建立视觉 SLAM 的关键帧数据库。

为了实现地图复用，算法在两个建图线程中设计了地图的存储和读取功能，在完成全局地图的构建后，将栅格地图与特征点地图以二进制形式保存，并储存其上的关键帧词袋信息与位姿信息，以在运行定位模块时恢复为复合地图，提高效率。

其后，在导航定位过程中，利用视觉信息进行快速粗定位：对相机的当前帧图像提取特征点与词袋模型，在关键帧数据库中搜索相似关键帧，通过求解 PnP 问题解算出当前帧与候选关键帧的相对位姿，在位姿变换后可得到当前相机在特征点地图中的全局位姿。

最后,利用位姿映射关系,将视觉快速定位得到的位姿信息变换到栅格地图中,将该结果作为先验信息,输入到基于 AMCL 的精确定位模块,以缩小地图的候选搜索区域,最终经粒子收敛后实现对移动机器人位姿的精确估计。

3.3 基于词袋模型的视觉快速定位

视觉快速定位模块旨在利用 RGB-D 相机,基于词袋模型(bag of words, BoW)快速获取机器人在特征点地图中的粗定位。

在视觉定位算法中,图像中的特征点即对应视觉地图中的路标点,由于相机运动的连续性,或在出现回环时,关键帧间会存在共视关系。为快速获取粗定位信息,需要以高效率的方法在关键帧序列中搜索共视关键帧,因此算法采用词袋模型完成该步骤。该方法在离线阶段,对大量图像提取特征点和描述子,然后用分层 K-Means 聚类算法将描述子划分为若干类别,每个类别代表一个视觉单词,将这些单词组成一个视觉词典,并用 K 叉树存储;同时,为每个单词计算权重,表示该单词在数据集中出现的频率。如图 3-3 所示,在搜索相似图像时,通过将图像中的特征点映射到预先构建的视觉词典中,将图像特征转化为一个稀疏的向量表示,通过该向量比较两帧图像中单词的相似度,可以快速查找出最相似的关键帧^[47]。




图 3-3 基于词袋模型的共视关键帧搜索过程

为进一步得到机器人位置,算法需对不同关键帧间的特征点对进行匹配,求解图像帧位置关系。在此过程中,图像中的关键点与其相应的描述子用于表征图像的本质特征,不应该受图像的放大缩小旋转影响而改变,且不同特征描述子应具有独特性、排他性,尽可能减少彼此间的相似性。因此,算法采用 ORB 特征点来提取图像信息,利用 Orientd FAST 算法来快速检测各个角点,提取的关键点具备尺度不变

性和旋转不变性。随后，使用改进的 BRIEF 特征描述，以二进制向量的形式对每个点计算其描述子，该方法计算速度快并且不丢失方向性。算法中利用二进制向量间的汉明距离表示特征点对的相似程度，将所有特征点对之间的汉明距离中的最小值的两倍作为判定特征匹配的阈值。

基于以上内容，在全局地图的构建过程中，算法利用视觉 SLAM 构建特征点地图，对输入图像提取 ORB 特征与词袋模型，同时保存关键帧序列并记录其上的特征信息与在全局地图中的位置。在全局定位模式下，快速定位模块根据视觉传感器的当前帧图像在关键帧数据库中搜索候选关键帧，在进一步筛选后确定相似关键帧，选取 n 组匹配特征点对，由建图结果可获取关键帧特征点在视觉地图中对应的三维坐标，对应的当前帧特征点即为其投影在像素坐标系中的位置，从而可对相机位姿估计进行 PnP 问题解算，得出当前关键帧与相似关键帧的相对位姿，经过位姿变换得到当前时刻相机在视觉地图中的全局位姿，完成视觉全局定位。

具体而言，在视觉 SLAM 的建图阶段，算法会利用词袋模型将图像的特征描述为向量，并建立包含关键帧位姿、特征点与 BoW 信息的关键帧数据库。

对于图像 A，其词袋模型 $\mathbf{v}_A$ 可表示为

$$\mathbf{v}_A = \{(\mathbf{w}_1, \eta_1), (\mathbf{w}_2, \eta_2), \dots, (\mathbf{w}_N, \eta_N)\} \quad (3-1)$$

其中， η_i 为单词 $\mathbf{w}_i$ 通过 TF-IDF (Term Frequency – Inverse Document Frequency) 方法^{[56][57]}表示的单词权重，将某单词中的特征数量相对于所有特征数量的比例记为 IDF，TF 则表示某个特征在单幅图像中出现的频率。假设所有特征数量为 n ， $\mathbf{w}_i$ 数量为 n_i ，则

$$\eta_i = TF_i \times IDF_i \quad (3-2)$$

$$TF_i = n_i / n \quad (3-3)$$

在进行全局定位时，利用当前帧与共视图关键帧 BoW 模型之间的 L_1 范数^[58]来度量其相似度分数：

$$s(\mathbf{v}_A - \mathbf{v}_B) = 2 \sum_{i=1}^N |\mathbf{v}_{A_i}| + |\mathbf{v}_{B_i}| - |\mathbf{v}_{A_i} - \mathbf{v}_{B_i}| \quad (3-4)$$

同时，为避免引入绝对的相似性阈值，采用先验相似度 $s(\mathbf{v}_t, \mathbf{v}_{t-\Delta t})$ 表示某时刻关键帧图像与上一时刻的关键帧的相似性。如式(3-5)所示，将其他相似度分值参照此

值进行归一化，表示当前帧与关键帧数据库中某帧的相似度，超过了当前帧与上一关键帧相似度的比值。

$$s'(v_t, v_{t-\Delta t}) = s(v_t, v_{t_j}) / s(v_t, v_{t-\Delta t}) \quad (3-5)$$

通过词袋模型相似度比对，可在关键帧数据库中选定相似关键帧进行特征匹配，得到 n 对匹配的特征点。其中关键帧图像中的特征点在视觉地图中存在对应的 3D 路标点 $\mathbf{P}_i^w = (x_i^w, y_i^w, z_i^w)$ ，当前帧图像中的特征点即为其在相机坐标系中的 2D 投影 $\mathbf{P}_i^l = (u_i, v_i)$ 。因此，与 2.3 节类似，可以利用 EPnP 方法求解该 3D-2D 的位姿估计问题，得到当前时刻相机坐标系相对于世界坐标系的变换矩阵，即为移动机器人在特征点云地图中的粗定位。

3.4 建立地图间位姿映射

栅格地图的初始位置由激光雷达建图线程中使用的前端位姿跟踪起始信息确定，而特征点地图的初始坐标系则为视觉建图线程的第一个关键帧的相机坐标系位置，因此，两地图坐标之间存在变换关系。考虑到两地图在建图过程中的尺寸与误差优化，若仅采用激光雷达与视觉相机联合标定结果进行坐标转换，对齐效果较差。为了能够将视觉粗定位信息用于精确定位，需要进一步取得移动机器人在激光栅格地图中的定位信息。因此，算法通过建立两地图间的位姿映射关系，能够便捷地在栅格地图与点云地图中得到全局一致的定位结果。

在建图阶段，全局定位算法通过对齐建图运动轨迹的方式，将特征点地图与激光栅格地图进行对齐。算法定义了激光与视觉两算法在建图过程的运动轨迹之间的距离损失函数，并以轨迹对齐问题构建了最小二乘优化问题，来建立两地图间的位姿关系映射。由于两建图线程是同步进行的，在进行时间同步处理后，移动机器人的轨迹位姿可以用各种传感器的观测信息表示。在完成视觉快速定位后，根据位姿映射关系即可得到移动机器人在栅格地图中的粗定位。

轨迹对齐需要视觉与激光建图过程中在同一时刻的位姿，但两种算法的计算频率不同，视觉关键帧与激光雷达帧的时间戳不能完全对应。因此算法对激光 SLAM 建图轨迹进行线性插值处理，以计算对应于相机关键帧序列的位姿。

在前端位姿跟踪过程中，算法采用旋转矩阵来描述空间旋转，但旋转矩阵用 9 个量描述 3 自由度的旋转，具有冗余性。为计算方便，在插值计算过程中使用四元数表示旋转。四元数可以看作是复数的推广，可以用来表示旋转的连续运动，在紧凑表示旋转的同时，避免了欧拉角表示方法的万向锁问题，而且不需要存储

每一步的旋转矩阵，从而能够平滑地连接两个姿态，方便进行插值运算。四元数 $\mathbf{q}$ 包括一个实部和三个虚部，形如：

$$\mathbf{q} = w + xi + yj + zk \quad (3-6)$$

其中， w 为四元数的实部， i 、 j 和 k 为四元数的三个虚部，并且满足：

$$\begin{cases} i^2 = j^2 = k^2 = -1 \\ j = k, ji = -k \\ jk = i, kj = -i \\ ki = j, ik = -j \end{cases} \quad (3-7)$$

四元数与旋转向量可进行转换。绕单位向量 $\mathbf{u} = [u_x, u_y, u_z]^T$ 旋转角度 θ 的过程可以旋转向量的形式表示为 $\boldsymbol{\varphi} = \mathbf{u}\theta$ ，将四元数的 3 个虚部与空间中的 3 个轴相对应，则对应四元数的指数对数映射关系为：

$$\mathbf{q} = \exp(\boldsymbol{\varphi}) = [\cos \frac{\theta}{2}, \mathbf{u} \cdot \sin \frac{\theta}{2}]^T \quad (3-8)$$

$$\mathbf{u}\theta = \log(\mathbf{q}) \quad (3-9)$$

线性插值通过建立一个函数 $\mathbf{q}(t)$ ，使得机器人在一段时间内可以匀速绕固定轴从 $\mathbf{q}_0$ 旋转到 $\mathbf{q}_1$ 。对四元数的插值需要确保插值向量轨迹在单位球面上。将旋转向量通过指数映射到四元数，则得到插值函数：

$$\begin{cases} \mathbf{q}(t) = \mathbf{q}_0 \otimes \exp(t\Delta\boldsymbol{\varphi}) \\ \mathbf{q}(t) = \mathbf{q}_0 \otimes \exp(t \log(\mathbf{q}_0 \otimes \mathbf{q}_1)) \end{cases} \quad (3-10)$$

最终得到插值结果：

$$\mathbf{q}(t) = \mathbf{q}_0 \otimes \begin{bmatrix} \cos\left(t \frac{\Delta\varphi}{2}\right) \\ \mathbf{u} \sin\left(t \frac{\Delta\varphi}{2}\right) \end{bmatrix} \quad (3-11)$$

在时间同步处理后，为将激光建图与视觉建图的关键帧对齐，按式(3-12)构建最小二乘问题，与 2.5.1 节相似，通过优化两地图间的坐标变换关系，使得轨迹位姿观测残差的平方和最小。

$$\min_{\mathbf{R}, \mathbf{t}} \left\{ \sum_{i=0}^n \|\mathbf{p}_{li} - (\mathbf{R}\mathbf{p}_{2i} + \mathbf{t})\|_2^2 \right\} \quad (3-12)$$

式中， $\mathbf{p}_{li}$ 、 $\mathbf{p}_{2i}$ 分别为特征点地图和激光栅格地图第 i 个关键帧的位姿， $\mathbf{R}$ 、 $\mathbf{t}$ 是变换关系中的旋转和平移。

通过求解该优化问题，即可建立地图间位姿关系映射。在算法完成视觉快速定位后，可根据映射关系将视觉粗定位结果变换到栅格地图。

3.5 基于 AMCL 方法的精确定位

AMCL 算法在无初始位姿信息的情况下，通常在全局地图范围内随机分布粒子，或直接以地图坐标系原点附近的地图区域为起点进行初始化，这将使算法在全局定位过程中生成大量无效或错误的粒子，对定位效率造成影响。而在本算法中，通过视觉快速定位得到的粗定位信息可以作为先验信息，提供给 AMCL 模块进行精确定位，使得算法在激光特征单一、机器人静止或少量运动的情况下，也能实现可靠定位。

为了估计精确的位置和姿态，AMCL 算法利用一组随机粒子来表示机器人的可能位置。在给定初始位姿后，算法按照多元正态分布产生随机粒子。随机粒子的位置和姿态分解为 x 、 y 和 θ 三个部分，分别服从高斯分布，其中均值和方差由初始位姿和设定参数决定，从而产生随机粒子。

给定初始位姿和定位的范围，在粗定位结果附近按照式(3-13)随机产生 M 个粒子 $\chi_t = \{x_t^{[1]}, x_t^{[2]}, \dots, x_t^{[M]}\}$ ，表示移动机器人的可能位姿。

$$P_i(z|x, m) = \eta \frac{1}{\sqrt{2\pi b}} e^{-\frac{1}{2} \frac{(z - z_{\text{exp}})^2}{b}} \quad (3-13)$$

随后，AMCL 算法会根据传感器反馈信息动态地调整分布，来估计机器人在时间段内的位移和旋转量，对粒子进行运动预测。算法直接采用第 2 章中基于多源传感信息融合的里程计信息，完成对 χ_t 中各粒子的预测更新。对于每个粒子 $x_t^{[M]}$ ，定期根据机器人运动模型与前端位姿跟踪数据更新其位姿 $x_{t+1}^{[M]}$ ，如式(3-14)所示，得到预测粒子集。

$$x_t^{[m]} = p(x_t|u_t, x_{t-1}^{[m]}) \quad (3-14)$$

在考虑了里程计的不确定性之后，AMCL 算法会将每个粒子更新为其在预测后的位置附近的新状态。这样一来，粒子就能够捕捉到机器人运动后可能的位置和姿态。

AMCL 算法中常采用似然域模型或波束模型来确定粒子的重要性权值。其中似然域模型通过计算传感器终点距离已知地图上最近障碍物的距离，来评估传感器测

量结果的概率，以建立概率地图模型。模型采用混合参数混合测量噪声 z_{hit} 、测量失败 z_{max} 与随机测量 z_{rand} 三种噪声表达，其表达式为：

$$p(z_i^k | x_t, m) = \begin{bmatrix} z_{hit} \\ z_{max} \\ z_{rand} \end{bmatrix}^T \cdot \begin{bmatrix} p_{hit}(z_i^k | x_t, m) \\ p_{max}(z_i^k | x_t, m) \\ p_{rand}(z_i^k | x_t, m) \end{bmatrix} \quad (3-15)$$

似然域模型不考虑传感器射线上的障碍物，而只关注传感器测量终点的位置。因此，该方法可在全局地图建立后预先计算好似然域，通过查表得到粒子权重结果，从而计算速度较快；同时似然域模型具有较好的光滑性，不会因为机器人位置的微小变化而导致测量概率的剧烈变化。

因此，本算法在更新预测粒子集 χ_t 后，结合似然域观测模型，通过激光雷达观测结果计算每个粒子的权重，并对权重进行归一化，表示其与真实位姿的相似度，如式(3-16)所示。

$$w_t^{[m]} = w_t^{[m]} p_{t_likelihood}^{[m]} \quad (3-16)$$

式中， $p_{t_likelihood}^{[m]}$ 为激光栅格地图中粒子 $x_t^{[m]}$ 所在位置的似然域模型分布概率。

在新一轮迭代中，算法依照粒子权重进行重采样，从原始粒子集合中抽取新的粒子集合，使得权重高的粒子更容易被保留，权重低的粒子被淘汰。在此过程中，算法通过 KLD 散度的计算，基于采样的近似质量的统计界限来控制粒子数量和分布。KLD 散度通过动态变化的上界 M_x 动态调整粒子数量，如式(3-17)所示。

$$M_x := \frac{k-1}{2\varepsilon} \left\{ 1 - \frac{2}{9(k-1)} + \sqrt{\frac{2}{9(k-1)}} z_{1-\delta} \right\}^3 \quad (3-17)$$

式中， k 为当前已添加粒子对（离散化的）状态空间的覆盖数量， ε 为真实后验与基于采样的近似后验之间的误差， $z_{1-\delta}$ 表示近似分布在概率 $(1-\delta)$ 时候的值。

根据重采样后的粒子集合，计算机器人位姿的最大似然估计，即为全局定位模块输出的精确定位。

此外，当机器人遭到“绑架”或者误差累积过大时，会导致所有粒子都与真实位姿不匹配。为了解决这个问题，算法中维护着长期似然权重均值 w_{slow} 与短期似然权重均值 w_{fast} 。当发生定位丢失时， $w_{fast} < w_{slow}$ ，则按 $1 - w_{fast}/w_{slow}$ 的随机采样概率，依照先验定位信息与概率分布，向粒子集合 χ_t 中随机注入新的粒子，随着移动机器人运动，粒子群会在后续迭代中逐渐收敛至正确位姿。

3.6 小结

本章分析了基于单线激光雷达的 AMCL 算法在无初始位姿信息的情况下存在的问题；并基于视觉与激光结合的方式，在全局定位过程中，分别构建了栅格地图与特征点地图，并建立两者间的位姿映射关系；在移动机器人定位丢失时，利用信息丰富的视觉快速定位获取粗定位，将结果作为先验位姿信息，在 AMCL 定位算法的基础上实现了快速、可靠的全局定位。

在机器人的导航过程中，全局定位能够解决移动机器人定位丢失问题，同时在路径规划中为机器人提供目标点的信息。本章算法综合利用视觉方法在环境特征感知方面的丰富性，以及激光雷达定位精确的优点，改善了全局定位算法的准确性与运算速度，能够直接提高机器人导航与路径规划的效果。

第4章 实验验证与分析

4.1 实验平台

图 4-1 为在实验验证中搭建的移动机器人实验平台。实验平台主要包含车体、工控机、底盘系统等部分，可用于移动机器人建图、定位、导航、路径规划等多种功能的开发。



图 4-1 移动机器人实验平台

该实验平台底盘为单舵轮模型，由一个立式舵轮与两个固定从动轮组成。除了基本的机械结构外，平台搭载轮式编码器、IMU、深度相机和激光雷达等传感器，使得平台能够方便地测量自身运动与感知外部环境，实现论文算法要求的测量环境。



图 4-2 R2000 单线激光雷达

平台选用倍加福 R2000 单线激光雷达作为激光定位算法的传感器,其外观如图 4-2 所示,其采用不可见的红外激光完成距离测算,对自然物或反射板的检测范围为 30 米,高角分辨率达 0.043° ,最高扫描频率为 50Hz,每秒能输出 84000 个扫描点,可满足对目标物体进行轮廓扫描所需的高精度测量的技术要求。

系统中所用视觉相机为 Intel RealSense 深度摄像头 D455,其外观如图 4-3 所示。其分辨率最高 1280×800 ,能以最高每秒 90 帧的速度拍摄即时场景,并搭载深度传感器,为移动机器人提供深度感知能力。其深度视场角为 $87^\circ \times 58^\circ$,有效测量范围为 0.6-6 米,在 4 米处误差小于 2%。同时,摄像头中集成了惯性测量单元 Bosch BMI055,由一个三轴 12 位加速度传感器和一个三轴 16 位、 $\pm 2000^\circ/\text{s}$ 的陀螺仪构成,加速度分辨率为 0.98 mg ,陀螺仪分辨率为 $0.1^\circ/\text{s}$,可获取摄像头运动信息,由此提高机器人和无人机的环境感知能力。



图 4-3 Intel RealSense D455 深度相机

轮式编码器采用 Kubler 紧凑型增量编码器 3610/3620,安装于电机顶端,采用光学传感技术,分辨率可达每转脉冲数 2500 ppr,如图 4-4 所示。



图 4-4 Kubler 增量式速度编码器

用于算法测试的工控机为 Advantech MIC-770,如图 4-5 所示,搭载 I7-9700TE 8 核 8 线程 CPU,安装的计算机操作系统为 Ubuntu 18.04 LTS,开发环境配置还包括 OpenCV4.4.0、Eigen3.1.0、Ceres、pangolin、DBoW2、Sophus 和 g2o 等开源的函数库。车载系统搭载基于 ROS (Robot Operating System) 平台开发的 SLAM 系统,实现机器人定位与建图功能。



图 4-5 Advantech MIC-770 工控机

ROS 是一个基于 BSD 授权协议的开源机器人操作系统，能够提供通用的操作系统和通信结构，包括底层设备控制，进程间消息传递，编译、修改代码所需的工具和库函数、以及包管理等，使得机器人软件开发更加高效。其最初由斯坦福大学人工智能实验室（AI Lab）开发，现已成为全球范围内机器人研究和开发的标准平台。




图 4-6 ROS 系统通讯机制

如图 4-6 所示，ROS 采用基于节点的分布式通讯机制，采用 TCP/IP 协议实现节点间通信，通过话题（Topic）、服务（Service）、动作（Action）等多种通信方式，可实现数据的异步与同步通信，并提供参数服务器用于存储公共参数。节点是 ROS 系统中的最小运行单位，可以是提供感知、控制、规划等功能的程序，也可以是硬件设备或仿真模型等。这种分布式通讯机制使得 ROS 能够支持多种不同的机器人硬件和软件平台，并且可以方便地扩展和定制功能。

4.2 传感器标定

由于传感器自身存在误差,如 IMU 中的加速度计零偏等,为实现定位算法的精确定位与数据融合,需要对各个传感器进行标定,以获取传感器内参与传感器之间的外参等。

相机标定需要测定相机的内参和畸变参数,内参包括焦距、主点坐标和像素尺寸等,畸变参数包括径向畸变和切向畸变。相机标定的目的是得到图像坐标与空间坐标的变换关系。其标定原理如 2.3 节所述,使用 Kalibr 工具进行针孔模型相机内参标定,畸变参数则选择 k_1, k_2, p_1, p_2 ,通过标定板中的角点计算相机内参。标定过程需要已知尺寸的 Apriltag 或棋盘格等标定板,实验中选用 april_6x6_80x80cm 标定板,如图 4-7 所示。




图 4-7 Apriltag 标定板

受温度、电压、机械应力、地球自转角速度和其他外部扰动等因素影响,IMU 测量值与真实值之间存在一定的漂移,其中静止时不为零的常数偏置为零偏噪声。

IMU 标定需测量加速度计和陀螺仪的噪声标准差和随机游走,使用基于 Allan 方差分析法的工具包 imu_utils 进行 IMU 标定。将 IMU 静止放置后,录制时长为 2 小时的 bag 数据包用作输入数据,得到标定结果。

相机与 IMU 联合标定需测定相机坐标系与 IMU 本体坐标系间的位姿变换矩阵及时间戳误差。联合标定过程同样通过 Kalibr 工具实现,充分激励 IMU 并录制数据,得到相机与 IMU 间的外参。

同样地,在视觉与激光结合的全局定位算法中,也需要获取相机与激光雷达间的位姿变换矩阵。本系统中选择 Autoware 提供的 Camera-LiDAR 联合标定工具包,如图 4-8 所示,通过激光点云与图像的可视化显示,人工选取 9 对对应点,完成相机与激光雷达相对位姿的求解。




图 4-8 Camera-LiDAR 联合标定

4.3 前端定位实验

4.3.1 评价指标

评估 SLAM/VO 算法的表现通常从时耗、复杂度、精度多个角度切入，其中对精度的评估通常采用两个精度指标，绝对轨迹误差（Absolute Trajectory Error, ATE）和相对位姿误差（Relative Pose Error, RPE）。




图 4-9 绝对轨迹误差

绝对轨迹误差是估计位姿和真实位姿的直接差值，可直观反应估计轨迹的全局一致性。如图 4-9 所示，位姿跟踪结果与实际运动轨迹通常不在同一坐标系中，因此在计算前先将两者的轨迹通过旋转与平移变换对齐，对于尺度不统一的单目视觉

里程计，还需要进行放缩。通过最小二乘法求解估计轨迹与真实轨迹间的变换矩阵 $S \in SE(3)$ ，使两者尽可能重合，并测量轨迹误差。

对于第 i 帧位姿，其绝对轨迹误差定义如下：

$$F_i := Q_i^{-1} S P_i \quad (3-18)$$

相对位姿误差描述间隔单位时间 Δt 的两帧之间，估计轨迹与真实轨迹位姿差的局部精度，对应于轨迹的漂移，如图 4-10 所示。




图 4-10 相对轨迹误差

对于第 i 帧位姿，其相对位姿误差定义如下：

$$E_i := (Q_i^{-1} Q_{i+\Delta})^{-1} (P_i^{-1} P_{i+\Delta}) \quad (3-19)$$

绝对轨迹误差与相对位姿误差具有强烈的相关性，但含义不尽相同。由于本实验通过以不同算法在同一场景下驶过同一段轨迹的方式，对前端定位结果进行评价，故直接选择绝对轨迹误差的来评估里程计精度，计算各测量点处绝对轨迹误差的均方根作为整体评价指标，即

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (tra1_i - tra2_i)^2} \quad (3-20)$$

其中， i 为实验选取的测量点，共计 m 处。

4.3.2 实验过程与结论

由于实验平台的真实轨迹难以测量，因此为了量化评估算法的轨迹误差，在室内大厅环境下，采用固定测量点、控制移动机器人依次通过的方式进行实验验证，测量运动轨迹误差，并计算各测量点处误差的均方根作为最终评价指标。

利用实验平台运动过程中采集到的传感器数据，分别采用轮式编码器位姿估计方法、视觉里程计位姿估计方法与本文多传感器融合的位姿估计方法对实验平台的

位姿信息进行实时估计，并将各方法下的里程计信息进行记录。根据相关位姿估计信息，绘制运动轨迹，最终得到各方法下的实验平台运动轨迹如图 4-11 所示。




图 4-11 各位姿估计方法下的实验平台运动轨迹

由图 4-11 可知，在基于单一传感器的前端定位算法中，根据里程计信息绘制的运动轨迹与测量点之间存在偏差，尤其轮式编码器对应的运动轨迹，随着移动机器人行程增加误差逐渐增大，最终偏差严重，这将对后续的全局定位与导航避障工作造成不利影响。而采用本文多源传感信息融合的前端定位算法绘制的图像中，显示的运动轨迹能够较好地经过各测量点，说明其定位误差更小。

表 4-1 前端定位实验结果（单位：m）

测量方法	初始点	1	2	3	4	5	6	7
轮式编码器	0	0.048	0.251	0.606	0.894	0.9	0.988	0.722
视觉里程计	0	0.086	0.025	0.2	0.192	0.09	0.051	0.1
多传感器融合 算法	0	0.039	0.026	0.018	0.023	0.045	0.02	0.082

计算由里程计信息得到的运动轨迹距离各测量点的最小距离，整理为表 4-1。将结果绘制为误差折线图，如图 4-12 所示。可见，轮式编码器的输出位姿偏差严重，并且考虑到在环形的路线下，轮式编码器在行程后期的误差测量值偏小，说明其随行程的增加有明显的误差累积；视觉里程计存在一定误差，但由于经过局部优化，整体误差较小，只在某些测量点处有较大偏差；而本文算法由于融合了多种传感器，轨迹精度整体水平更高，输出位姿在各测量点处都能较为吻合。




图 4-12 运动轨迹误差折线图

根据式(3-20)统计表 4-1 数据，计算三种运动轨迹在各测量点处的绝对轨迹误差的均方根，作为最终评价指标。计算得：仅采用轮式编码器的位姿估计方法的均方根误差为 0.665m；仅采用视觉里程计的位姿估计方法的均方根误差为 0.115m；本文采用的多传感器融合的位姿估计方法的均方根误差为 0.039m，证明其轨迹精度相较前两种方式有明显提升。

4.4 全局定位实验

为验证全局定位算法的效果，设计了对比实验。如 3.1 节所述，AMCL 算法在移动机器人全局定位算法中被广泛采用，其综合表现性能优秀。而本文基于视觉与激光融合的全局定位算法是在 AMCL 算法的基础上结合视觉方法加以改进，因此在该对比实验中，分别采用本文算法与原 AMCL 算法在建立的激光栅格地图中进行全局定位，以比较算法改进前后的全局定位精度、时间与成功率等指标。

实验在室内环境下进行，在环境中建立场景地图如图 4-13 所示。其中，左侧为激光雷达建立的占据栅格地图，其中白色区域为可以行驶的无障碍区域，形状不规

则的黑色和灰色区域为不可行驶的存在未知障碍物的区域；右侧为视觉相机建立的特征点地图，蓝框为视觉建图线程储存的关键帧序列，其他点云为建立的地图点，其中红色表示当前帧对应的地图点，黑色代表存储的其他地图点。




图 4-13 栅格地图与特征点地图

实验过程中，在场景选取若干个测量点 A-G，在各测量点间多次进行机器人“绑架”实验，即在关闭定位算法的情况下移动机器人。分别利用 AMCL 算法与基于激光与视觉结合的全局定位算法对机器人进行全局定位，选取定位精度、时间与成功率等指标以定量评估算法效果。在进行全局定位实验时，将两种算法的检测超时时间都设为 30 秒。由于最终定位结果是通过迭代优化得到的，给定阈值 T_l ，在检测超时后，根据定位算法输出结果 p_{robot} 与测量点位置 p_{goal} 之间的偏差，判定是否定位成功。

整理各次实验的数据如表 4-2 所示。

表 4-2 全局定位实验结果

试验次数	定位方式	定位结果偏差/cm			算法用时/s
		x	y	偏航角	
1	AMCL	4.72	3.89	0.077	12.14
	融合算法	4.85	0.75	0.032	9.37
2	AMCL	-	-	-	失败
	融合算法	4.05	6.01	0.03	1.57
3	AMCL	3.96	4.78	0.084	16.91
	融合算法	6.60	4.74	0.129	2.38
4	AMCL	-	-	-	失败
	融合算法	6.60	4.78	0.129	2.38
5	AMCL	4.03	3.71	0.1	26.52
	融合算法	4.84	3.54	0.039	3.80

续表 4-2 全局定位实验结果

试验次数	定位方式	定位结果偏差/cm			算法用时/s
		x	y	偏航角	
6	AMCL	5.28	3.07	0.094	18.36
	融合算法	2.04	4.16	0.067	11.76
7	AMCL	4.75	3.88	0.093	21.82
	融合算法	5.45	2.03	0.004	13.49
8	AMCL	4.23	3.18	0.1	19.72
	融合算法	2.84	0.10	0.033	10.50
9	AMCL	4.00	4.17	0.102	26.45
	融合算法	4.30	3.33	0.021	9.51
10	AMCL	-	-	-	失败
	融合算法	3.06	3.99	0.008	4.32
11	AMCL	-	-	-	失败
	融合算法	2.72	0.96	0.004	4.36
12	AMCL	-	-	-	失败
	融合算法	6.01	5.84	0.049	6.48
13	AMCL	4.13	4.16	0.1	18.16
	融合算法	6.61	1.43	0.029	2.90
14	AMCL	4.04	2.79	0.087	18.27
	融合算法	4.90	1.98	0.043	2.56
15	AMCL	3.90	3.37	0.102	13.02
	融合算法	2.17	4.23	0.053	5.33
16	AMCL	3.59	3.12	0.094	12.32
	融合算法	3.67	4.94	0.016	3.51
17	AMCL	3.60	3.45	0.078	14.39
	融合算法	6.26	5.81	0.038	10.95
18	AMCL	4.47	3.92	0.088	24.15
	融合算法	3.56	1.30	0.13	8.95
19	AMCL	-	-	-	失败
	融合算法	2.03	4.59	0.054	6.23
20	AMCL	-	-	-	失败
	融合算法	0.99	3.41	0.122	8.13

由实验结果可知，在相同的全局定位条件下，AMCL 算法的定位用时更长，且多次出现定位失败或定位超时的情况，最终算法全局定位成功率为 65%。通过分析可知，定位失败与超时相对集中于某些测量点附近，多发生在定位位置与建图起始位置相差较远时，这是由于 AMCL 算法在无先验信息时，直接以地图原点作为粒子分布中心进行粒子更新，因此在实际位置远离与建图起始位置时，注入的随机粒子难以使粒子群运动收敛至正确位置；在“绑架”位置的环境信息相较地图信息发生局部改变时，AMCL 算法也更容易发生定位失败，说明算法鲁棒性相对较差。

如图 4-14 所示，在定位失败时，AMCL 算法的粒子收敛，但实际激光雷达输出与栅格地图相差甚远，表示定位结果错误。




图 4-14 AMCL 算法定位失败

相对而言，由论文的视觉与激光结合的全局定位算法的实验结果可见，该算法在定位用时方面有显著提升，且在 20 次实验中未出现定位失败的情况，效果明显优于原 AMCL 算法。

算法的粒子收敛过程如图 4-15 所示，机器人首先通过视觉特征的提取与匹配，快速估计出相机位姿，将视觉快速定位结果变换到栅格地图后，作为精确定位模块的先验信息，在该位置附近按一定的分布产生随机粒子，如图(a)所示，其中每一个红色箭头代表不同的粒子。在图(b)中，当移动机器人位姿发生改变后，粒子群根据传感器观测信息与前端定位信息进行更新，直至收敛，得到精确定位结果，如图(c)所示。

为进一步对比两种方式的定位精度、速度、成功率等指标，统计所有定位成功情况下的各测量点处的定位结果均值，并按不同的超时时间统计两种算法的定位成功率，将表 4-2 中的实验对比结果汇总于表 4-3。




图 4-15 粒子收敛过程

表 4-3 全局定位算法实验对比结果汇总

参数	原AMCL算法	基于视觉与激光融合的全局定位算法
$\bar{x}/\text{cm}$	4.2	4.2
$\bar{y}/\text{cm}$	3.6	3.4
$\bar{\theta}/\text{rad}$	0.092	0.052
成功率 ($\leq 5\text{s}$)	0%	45%
成功率 ($\leq 15\text{s}$)	20%	100%
成功率 ($\leq 25\text{s}$)	55%	100%

由表 4-3 可知，论文中基于视觉与激光融合的全局定位算法，在定位精度方面有小幅提升，但幅度不明显，这是由于算法的改进主要影响于粒子收敛的前期过程，对最终收敛结果的影响较小。但同时，论文算法在定位速度与成功率方面，相较原 AMCL 算法有显著提升。实验中论文算法均在 15s 内完成全局定位，平均耗时 6.4s，且 20 次实验全部定位成功；对比 AMCL 算法，即使仅在最终成功定位的实验中，平均也需要耗时 19.1s。这是由于算法针对蒙特卡洛定位方法易发生误匹配或全局搜索时间过长的问题，结合视觉定位方法丰富的环境特征感知能力与词袋模型的快速

定位能力进行了改进。整体上，本文所设计的基于视觉与激光融合的定位算法在全局定位时比基于单激光雷达的 AMCL 定位算法定位速度提高 66.5%，且以不同时长为限制的情况下统计的成功率均明显优于原算法。

实验对比表明，论文算法在保证移动机器人全局定位精度的同时，大幅提高了定位速度与成功率，使得定位系统在位置丢失后有较强的恢复能力，提高了系统准确率和效率，有利于移动机器人在复杂环境下的稳定运行。

4.5 小结

本章通过搭建实验平台并进行传感器标定，将论文的移动机器人定位算法部署至实验平台，进行了一系列实车测试。在室内大厅环境下，将论文基于多源传感信息融合的前端定位算法，与基于单一传感器的里程计的位姿跟踪精度进行对比实验；同时，将论文结合视觉与激光的全局定位算法，与原 AMCL 定位算法的全局定位效果进行对比实验。

实验结果表明，本文提出的前端算法在生成轨迹的精度方面有明显提升，为导航与定位系统提供了良好的基础参照；而全局定位算法在保证精度的同时，大幅提高了移动机器人全局定位的效率与成功率，使移动机器人在定位丢失的情境下有更重的重定位能力，保证了移动机器人在复杂环境下的稳定运行。

第5章 总结与展望

5.1 本文的主要工作

本文主要研究了基于多源传感信息融合的移动机器人定位算法，对前端里程计定位与全局定位部分分别进行了改进，实现了一种紧耦合的多源传感信息融合算法，有效提高了移动机器人前端定位的定位精度；实现了一种结合视觉方法与蒙特卡洛方法的全局定位算法，提高了移动机器人全局定位的速度与成功率。文章的主要工作包含如下三个部分：

(1) 针对单一传感器精度低、特定运动条件下发生退化等问题，在自主移动机器人前端定位过程中，采用视觉相机、IMU 与轮式编码器等多种传感器，融合里程计信息进行算法研究。建立了基于编码器初始位姿的视觉里程计跟踪模型，以及各传感器的运动观测信息；建立了运动观测的非线性优化融合模型，并利用滑动窗口法构建最小二乘问题以对残差项进行优化。通过这些技术，可以实现对移动机器人运动状态信息的精准估计。

(2) 为解决移动机器人未知位置启动和定位丢失问题，提出了一种基于视觉与激光融合的全局定位算法。在建图阶段，利用视觉 SLAM 和激光 SLAM 分别建立特征点地图和激光栅格地图，通过轨迹对齐生成地图坐标的映射，并记录相机位姿与特征信息；在全局定位时，利用词袋模型进行快速视觉定位，并匹配得到栅格地图中的先验定位信息，再通过自适应蒙特卡罗定位算法迭代更新粒子完成精确定位，从而实现快速、准确的全局定位。

(3) 为验证算法有效性，搭建实验平台进行了一系列实车测试。在室内大厅环境下，将论文基于多源传感信息融合的前端定位算法，与基于单一传感器的里程计的位姿跟踪精度进行了横向对比；同时，将论文结合视觉与激光的全局定位算法，与原 AMCL 定位算法的全局定位效果进行了横向对比。实验结果表明，本文算法在前端运动轨迹的精度方面有明显提升，同时大幅提高了全局定位的效率与成功率，保证了移动机器人在复杂环境下的稳定运行。

论文的主要创新点如下：

(1) 在建立视觉里程计运动观测的特征匹配环节，构建了基于编码器初始位姿的跟踪模型，以控制候选匹配搜索区域；

(2) 基于滑动窗口法与非线性优化算法实现对前端里程计运动信息的融合，实现对移动机器人运动状态信息的精准估计。

(3) 将视觉快速定位得到的粗定位信息作为全局定位先验信息, 减少了 AMCL 算法中生成的大量无效粒子, 大幅提高了移动机器人全局定位的速度与成功率。

5.2 未来工作展望

本文对移动机器人定位算法开展研究, 相关算法虽取得一定成果, 但仍存在部分问题有待解决。后续研究工作可从以下几个方面展开:

(1) 在基于多源传感信息融合的前端定位算法中, 仅对输出速率较高的 IMU 完成了预积分计算, 而对轮式编码器则仅采用了迭代与插值的方式计算其位姿估计。在后续研究中, 可增加对轮式编码器运动观测的预积分计算, 以提高非线性优化过程的运算速度与计算精度。

(2) 在视觉里程计的运动观测章节中, 本文在 ORB-SLAM 采用恒速模型跟踪、参考关键帧跟踪、重定位跟踪等方式确定特征点匹配区域的基础上, 优先利用编码器位姿跟踪的方式估计控制匹配搜索区域, 后续研究中可对该跟踪模型下的特征匹配效果进行相关对比与改进。

(3) 论文的实验部分中, 未使用相关检测设备采集移动机器人运动过程中的真实运动轨迹, 而只采用了固定测量点的位置信息作为定位算法实际性能的对比基准, 后续研究中可采用轨迹真值获取装置进一步完善实验。

参考文献

- [1] T. Bailey, H. Durrant-Whyte. Simultaneous Localisation and Mapping (SLAM) Part 2: State of the Art[J]. Robotics and Automation Magazine, 2006.
- [2] 张鹏飞. 融合激光与视觉的移动平台定位研究[D]. 电子科技大学, 2020.
- [3] A. Doucet, N. De Freitas, K. Murphy, et al. Rao-Blackwellised particle filtering for dynamic Bayesian networks[C]// Proceedings of the Sixteenth conference on Uncertainty in artificial intelligence, 2000, 176-183.
- [4] M. Montemerlo, S. Thrun, D. Koller, et al. FastSLAM: A factored solution to the simultaneous localization and mapping problem[J]. Aaai/iaai, 2002, 593-598.
- [5] M. Montemerlo, S. Thrun, D. Koller, et al. FastSLAM 2.0: An improved particle filtering algorithm for simultaneous localization and mapping that provably converges[C]// IJCAI, 2003, 1151-1156.
- [6] Grisetti G, Stachniss C, Burgard W. Improved Techniques for Grid Mapping with Rao-Blackwellized Particle Filters[J]. IEEE Transactions on Robotics, 2007,23(1): 34-46.
- [7] G. Dissanayake, S. Huang, Z. Wang, et al. A review of recent developments in simultaneous localization and mapping[C]// 2011 6th International Conference on Industrial and Information Systems, 2011, 477-482.
- [8] K. Konolige, G. Grisetti, R. Kümmerle, et al. Efficient sparse pose adjustment for 2D mapping[C]// 2010 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2010, 22-29.
- [9] Konolige, Kurt et al. Efficient Sparse Pose Adjustment for 2D mapping. 2010 IEEE/RSJ International Conference on Intelligent Robots and Systems (2010): 22-29.
- [10] S. Kohlbrecher, O.V. Stryk, J. Meyer, et al. A flexible and scalable slam system with full 3D motion estimation[C]// 2011 IEEE International Symposium on Safety, Security, and Rescue Robotics, 2011, 155-160.
- [11] W. Hess, D. Kohler, H. Rapp, et al. Real-time loop closure in 2D LIDAR SLAM[C]// 2016 IEEE International Conference on Robotics and Automation (ICRA), 2016, 1271-1278.
- [12] Hess, Wolfgang et al. Real-time loop closure in 2D LIDAR SLAM. 2016 IEEE International Conference on Robotics and Automation (ICRA) (2016): 1271-1278.
- [13] R. Kaijaluoto, A. Hyypä. Precise indoor localization for mobile laser scanner[J]. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 2015, XL-4/W5.

- [14] D. Fox, W. Burgard, S. Thrun. Markov localization for mobile robots in dynamic environments[J]. Journal of artificial intelligence research, 1999, 11: 391-427.
- [15] D. Fox, W. Burgard, F. Dellaert, et al. Monte Carlo localization: Efficient position estimation for mobile robots[J]. AAAI/IAAI, 1999, 1999(343-349): 2-2.
- [16] Nister D, Naroditsky O, Bergen J, et al. Visual odometry[C]// Proceedings of IEEE Conference on Computer Vision and Pattern Recognition (CVPR). USA: IEEE Press, 2004: 625-659.
- [17] 马科伟, 张镔石, 康宇航, 任子良, 程俊. 移动机器人中视觉里程计技术综述[J]. 计算机工程, 2021, 47(11): 1-10.
- [18] Matthies L, Shafer S. Error modeling in stereo navigation[J]. IEEE Journal on Robotics and Automation, 1987, 3(3): 239-248.
- [19] Davison A, Reid I, Molton N, et al. Monoslam: Real-time single camera SLAM[C]// IEEE Transactions on Pattern Analysis and Machine Intelligence, 2007, 29(6):1052–1067.
- [20] Klein G, Murray D. Parallel tracking and mapping for small AR workspaces[C]// Proceedings of the 6th IEEE and ACM International Symposium on Mixed and Augmented Reality, Nara. USA: IEEE Press, 2007: 225-234.
- [21] Forster C, Pizzoli M, Scaramuzza D. SVO: Fast semi-direct monocular visual odometry[C]// Proceedings of the IEEE International Conference on Robotics and Automation (ICRA), Hong Kong. USA: IEEE Press, 2014: 15-22.
- [22] Engel J, Koltun V, Cremers D. Direct sparse odometry [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (PAMI), 2017,40(3): 611-625.
- [23] Mur-Artal R, Montiel J M M, Tardos J D. ORB-SLAM: a versatile and accurate monocular SLAM system [J]. IEEE Transactions on Robotics, 2015, 31(5): 1147-1163.
- [24] Mur-Artal, Raul and Juan D. Tardós. ORB-SLAM2: An Open-Source SLAM System for Monocular, Stereo, and RGB-D Cameras. IEEE Transactions on Robotics 2016, 33: 1255-1262.
- [25] Labbe M, Michaud F. Online global loop closure detection for large-scale multi-session graph-based SLAM[C]// Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). USA: IEEE Press, 2014: 2661-2666.
- [26] Kerl C, Sturm J, Cremers D. Dense visual SLAM for RGB-D cameras[C]// Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). USA: IEEE Press, 2013: 2100-2106.
- [27] Endres F, Hess J, Sturm J, et al. 3-D Mapping With an RGB-D Camera[J]. IEEE Transactions on Robotics, 2013, 30(1): 177-187.

- [28] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [29] Bay H, Tuytelaars T, Van Gool L. Surf: Speeded up robust features [C]// Proceedings of the European Conference on Computer Vision (ECCV). Berlin: Springer, 2006: 404-417.
- [30] Rublee E, Rabaud V, Konolige K, et al. ORB: An efficient alternative to SIFT or SURF[C]//Proceedings of the International Conference on Computer Vision (ICCV). USA: IEEE Press, 2011 2564-2571.
- [31] Davison A J, Reid I D, Molton N D, et al. MonoSLAM: Real-time single camera SLAM[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (PAMI), 2007, 29(6): 1052-1067.
- [32] Tong Q, Peiliang L, Shaojie S. VINS-Mono: A Robust and Versatile Monocular Visual-Inertial State Estimator[J]. IEEE Transactions on Robotics, 2018, 12(3): 1-17.
- [33] Campos C, Elvira R, JG Rodríguez, et al. ORB-SLAM3: An Accurate Open-Source Library for Visual, Visual-Inertial and Multi-Map SLAM[J]. 2020.
- [34] 彭迎春. 移动机器人视觉里程计算法研究[D]. 燕山大学, 2019.
- [35] Newcombe R A, Lovegrove S J, Davison A J. DTAM: Dense tracking and mapping in real-time[C]//Proceedings of the International Conference on Computer Vision (CVPR). USA: IEEE Press, 2011: 2320-2327.
- [36] Wang S, Clark R, Wen H, et al. DeepVO: Towards end-to-end visual odometry with deep recurrent convolutional neural networks[C]// Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). USA: IEEE Press, 2017: 2043-2050.
- [37] Yin Z, Shi J. GeoNet: Unsupervised learning of dense depth, optical flow and camera pose[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). USA: IEEE Press, 2018: 1983-1992.
- [38] Tateno K, Tombari F, Laina I, et al. Cnn-slam: Real-time dense monocular slam with learned depth prediction[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). USA: IEEE Press, 2017: 6243-6252.
- [39] Scandaroli G G, Morin P. Nonlinear filter design for pose and IMU bias estimation[C]// 2011 IEEE Conference on Robotics and Automation. Shanghai: IEEE, 2011:4524-4530.
- [40] 程骏超, 房建成, 吴伟仁等. 一种激光陀螺惯性测量单元混合标定方法[J]. 中国惯性技术学报, 2014, 22(4):445-452.
- [41] 赵桂玲, 姜雨含, 李松. IMU 标定数学建模及误差分析[J]. 传感技术学报, 2016, 29(6):886-891.

- [42] Abbas, Tanveer et al. Measurement and Correction of Systematic Odometry Errors Caused by Kinematics Imperfections in Mobile Robots. 2006 SICE-ICASE International Joint Conference (2006): 2073-2078.
- [43] Tur J M M, Gordillo J L, Borja C A. A closed-form expression for the uncertainty in odometry position estimate of an autonomous vehicle[J]. IEEE Transactions on Robotics, 2005, 21(5):1017-1022.
- [44] Choi H, Yang K W, Kim E. Simultaneous global localization and mapping. IEEE/ASME Transactions on Mechatronics, 2014, 19(4):1160–1170.
- [45] Wu K J, Guo C X, Georgiou G, et al. VINS on wheels[C]// Proc of 2017 IEEE International Conference on Robotics and Automation (ICRA), Singapore: IEEE, 2017: 5155-5162.
- [46] 范堃. 自动导引车车载系统研究与实现[D]. 杭州: 浙江大学, 2013: 39-42.
- [47] 高翔. 视觉 SLAM 十四讲: 从理论到实践[M]. 北京: 电子工业出版社, 2017: 84-87, 243-244, 309-310.
- [48] Lepetit V, Moreno-Noguer F, Fua P. EPnP: An accurate $O(n)$ solution to the PnP problem[J]. International Journal of Computer Vision, 2009, 81(2): 155–166.
- [49] Taketomi T, Uchiyama H, Ikeda S. Visual SLAM algorithms: a survey from 2010 to 2016[J]. IPSJ transactions on computer vision and applications, 2017,9(1): 1-11.
- [50] Sibley G, Matthies L, Sukhatme G. Sliding window filter with application to planetary landing[J]. Journal of Field Robotics, 2010, 27(5): 587–608.
- [51] Fu Jianxun, Gao Feng, Chen Weixing, Pan Yang, Lin Rongfu. Kinematic accuracy research of a novel six-degree-of-freedom parallel robot with three legs[J]. Mechanism and Machine Theory, 2016, 102.
- [52] Robin Ping Guan, Branko Ristic, Liuping Wang, Jennifer L. Palmer. KLD sampling with Gmapping proposal for Monte Carlo localization of mobile robots[J]. Information Fusion, 2019, 49.
- [53] G. Grisetti, C. Stachniss, W. Burgard. Improving Grid-based SLAM with Rao-Blackwellized Particle Filters by Adaptive Proposals and Selective Resampling[C]// IEEE International Conference on Robotics & Automation, 2005, 2432-2437.
- [54] C. Cadena, L. Carlone, H. Carrillo, et al. Past, present, and future of simultaneous localization and mapping: Toward the robust-perception age[J]. IEEE Transactions on robotics, 2016, 32(6): 1309-1332.
- [55] Gálvez-López, Dorian and Juan D. Tardós. Bags of Binary Words for Fast Place Recognition in Image Sequences[C]// IEEE Transactions on Robotics 28 (2012): 1188-1197.
- [56] Sivic, J., & Zisserman, A. Video Google: a text retrieval approach to object matching in videos[C]// Proceedings Ninth IEEE International Conference on Computer Vision, 2003, 1470-1477 vol.2.

- [57] Robertson, S.E. (2004). Understanding inverse document frequency: on theoretical arguments for IDF[J]. J. Documentation, 2004, 60, 503-520.
- [58] D. Nister, H. Stewenius, Scalable recognition with a vocabulary tree[C]// 2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06), vol. 2, pp. 2161-2168, IEEE, 2006.